

学校代码: 10285  
学 号: 20204227029



# 硕士学位论文

(学术学位)



面向聊天机器人的对话理解研究

Research on Dialogue Understanding for Chatbots

研究生姓名	张冕
指导教师姓名	周夏冰、陈文亮
专业名称	计算机科学与技术
研究方向	自然语言处理
所在院部	计算机科学与技术学院
论文提交日期	2023 年 5 月



## 苏州大学学位论文独创性声明

本人郑重声明：所提交的学位论文是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含其他个人或集体已经发表或撰写过的研究成果，也不含为获得苏州大学或其它教育机构的学位证书而使用过的材料。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人承担本声明的法律责任。

论文作者签名：张晨 日期：2023.6

## 苏州大学学位论文使用授权声明

本人完全了解苏州大学关于收集、保存和使用学位论文的规定，即：学位论文著作权归属苏州大学。本学位论文电子文档的内容和纸质论文的内容相一致。苏州大学有权向国家图书馆、中国社科院文献信息情报中心、中国科学技术信息研究所（含万方数据电子出版社）、中国学术期刊（光盘版）电子杂志社送交本学位论文的复印件和电子文档，允许论文被查阅和借阅，可以采用影印、缩印或其他复制手段保存和汇编学位论文，可以将学位论文的全部或部分内容编入有关数据库进行检索。

涉密论文 ☐

本学位论文属 在 年 月解密后适用本规定。

非涉密论文 ☒

论文作者签名：张晨 日期：2023.6

导师签名：周夏水 日期：2023.6



# 面向聊天机器人的对话理解研究

## 摘 要

如何在对话中识别和理解说话者的情绪、话语中的共指和省略以及用户的不安全行为是人性化聊天机器人的关键能力<sup>[1,2]</sup>。本论文着重于这三个部分，并通过设计新的模型架构、新的学习框架或构建新的数据集来提升特定任务模型的性能。

具体而言，本文的研究内容主要包含三个章节：

(1) 基于变长上下文的对话情绪识别。现有的对话情绪识别方法使用固定的上下文窗口来识别说话者的情绪，这可能导致关键上下文信息的缺乏或冗余上下文信息的干扰。作为回应，本文探讨了可变长度上下文的好处，并提出了一种更有效的对话情绪识别方法，能够在预测不同话语的情绪时利用不同的上下文窗口。该方法包含两个新模块以实现可变长度上下文：1) 两个说话者感知单元，它显式地模拟说话者内部和说话者之间的依赖关系以提炼的对话上下文表示；2) 一个 top-k 规范化层，它确定最合适预测说话者情绪的对话上下文窗口。实验结果表明，该方法在三个公共数据集上优于几个强大的基线方法。

(2) 基于友邻学习的对话语义理解。目前的自训练方法，如标准自训练、协同训练、三重训练等，通常侧重于利用输入特征、模型架构和训练过程的差异提高模型在单个任务上的性能。自然语言处理中的许多任务都是关于语言的不同但相关的方面，并且为一项任务训练的模型可以成为其他相关任务的好老师。本文提出了友邻训练，一个跨任务的自训练框架，其中经过训练以执行不同任务的模型基于迭代训练、伪标签生成和再训练的过程，目的是相互帮助进而更好地选择伪标签。本文将友邻训练应用于两个对话理解任务，分别是对话语义角色标注和对话重写，实验结果表明与强基线相比，使用友邻训练框架训练的模型达到了最佳的性能，提升了模型理解对话语义的能力。

(3) 基于 SafeConv 的对话不安全行为理解。不安全行为的普遍存在是开放域端到端对话系统或聊天机器人面临的主要挑战之一，例如有毒语言和有害建议。然而，现有的对话数据集没有提供足够的注释来解释和纠正这种不安全的行为。本文构建了一个名为 SafeConv 的新数据集，用于研究对话安全性：(1) 除了话语级别的安全

标签外, SafeConv 还提供了话语中的不安全跨度, 这些信息能够指示哪些词造成检测到的不安全行为; (2) SafeConv 提供安全的替代回复以在检测到不安全行为时继续对话, 将对话引导到文明的轨迹。由于 SafeConv 有全面的标注, 本文对三个强大的模型进行了基准测试, 以缓解会话不安全行为, 包括检测不安全话语的检查器、提取不安全跨度的标记器以及将不安全响应转换为安全版本的重写器。此外, 本文还探索了将模型结合起来用于解释不安全行为和为聊天机器人排毒所带来的巨大好处。实验结果表明, 检测到的不安全行为可以用不安全的跨度很好地解释, 并且流行的聊天机器人可以在很大程度上被解毒。

综上, 本文首先提出了一种从可变长度的上下文中识别说话者情绪的新方法, 然后将跨任务监督注入自训练以选择高质量的伪标签来训练更好的对话语义角色标签和对话重写的模型, 最后构建一个具有全面标注的大规模数据集, 以帮助理解和纠正对话的不安全行为。

**关键词:** 对话情绪识别, 对话语义, 对话安全, 聊天机器人

作者: 张冕

指导老师: 周夏冰、陈文亮

# Research on Dialogue Understanding for Chatbots

## Abstract

How to understand speakers' emotion, the semantics of utterances, and the unsafe behavior of users in the conversation are crucial abilities for human-friendly chatbots. This thesis focuses on the three parts and improves task-specific models by designing new model architectures, new learning frameworks, or constructing new datasets.

Specifically, the main research content of this thesis includes three parts:

(1) Emotion recognition in conversation from variable-length context. Existing approaches to Emotion Recognition in Conversation (ERC) use a fixed context window to recognize speakers' emotion, which may lead to either scantiness of key context or interference of redundant context. In response, we explore the benefits of variable-length context and propose a more effective approach to ERC. In our approach, we leverage different context windows when predicting the emotion of different utterances. New modules are included to realize variable-length context: 1) two speaker-aware units, which explicitly model inner- and inter-speaker dependencies to form distilled conversational context, and 2) a top-k normalization layer, which determines the most proper context windows from the conversational context to predict emotion. Experiments and ablation studies show that our approach outperforms several strong baselines on three public datasets.

(2) Understanding conversational semantics with Friend-training. Current self-training methods such as standard self-training, co-training, tri-training, and others often focus on improving model performance on a single task, utilizing differences in input features, model architectures, and training processes. However, many tasks in natural language processing are about different but related aspects of language, and models trained for one task can be great teachers for other related tasks. In this work, we propose friend-training, a cross-task self-training framework, where models trained to do different tasks are used in an iterative training, pseudo-labeling, and retraining process to help each other for better selection of pseudo-labels. With two dialogue understanding tasks, conversational semantic role labeling and dialogue rewriting, chosen for a case study, we show that the models trained with the

friend-training framework achieve the best performance compared to strong baselines.

(3) Understanding unsafe behavior in conversation with SafeConv. One of the main challenges open-domain end-to-end dialogue systems, or chatbots, face is the prevalence of unsafe behavior, such as toxic languages and harmful suggestions. However, existing dialogue datasets do not provide enough annotation to explain and correct such unsafe behavior. We construct a new dataset called SafeConv for the research of conversational safety: (1) Besides the utterance-level safety labels, SafeConv also provides unsafe spans in an utterance, information able to indicate which words contribute to the detected unsafe behavior; (2) SafeConv provides safe alternative responses to continue the conversation when unsafe behavior detected, guiding the conversation to a gentle trajectory.

To summarize, we first propose a new method to recognize speakers' emotion from a variable length of context, then inject cross-task supervision into self-training to select high-quality pseudo-labels to train better models for conversational semantic role labeling and dialogue rewriting, and at last, construct a large-scale dataset with comprehensive annotations to help understand and correct conversational unsafe behavior.

**Keywords:** Emotion Recognition in Conversation, Conversational Semantics, Dialogue Safety, Chatbots

Written by Mian Zhang

Supervised by Xiabing Zhou, Wenliang Chen



# 目 录

<b>第一章 绪论</b>	1
1.1 研究背景和意义	1
1.2 相关工作	2
1.2.1 对话情绪识别	2
1.2.2 自训练	3
1.2.3 多任务学习	3
1.2.4 对话语义角色标注	3
1.2.5 对话重写	4
1.2.6 对话安全数据集	5
1.2.7 有毒行为的缓解	5
1.3 章节和内容安排	5
<b>第二章 基于变长上下文的对话情绪识别</b>	7
2.1 引言	7
2.2 方法	8
2.2.1 任务定义	8
2.2.2 方法	8
2.2.3 训练和预测	11
2.3 实验	12
2.3.1 设置	12
2.3.2 主要结果	12
2.3.3 消融实验	13
2.3.4 案例研究	15
2.4 本章小结	16
<b>第三章 基于友邻训练的对话语义理解</b>	17
3.1 引言	17
3.2 友邻训练框架	18
3.2.1 自训练	18
3.2.2 友邻训练	19
3.3 对话语义角色标注和对话重写之间的友邻训练	21
3.3.1 任务模型	21

3.3.2 翻译匹配器 .....	23
3.3.3 增强选择器 .....	24
3.4 实验 .....	24
3.4.1 设置 .....	24
3.4.2 基线 .....	26
3.4.3 主要结果 .....	27
3.4.4 分析 .....	28
3.4.5 案例研究 .....	29
3.5 本章小结 .....	30
<b>第四章 基于 SafeConv 的对话不安全行为理解 .....</b>	<b>31</b>
4.1 引言 .....	31
4.2 数据集构建 .....	33
4.2.1 数据源 .....	33
4.2.2 数据选择 .....	33
4.2.3 人工标注 .....	34
4.3 基础模型 .....	36
4.4 可解释的安全检查 .....	37
4.5 通过上下文重写纠正对话中的不安全行为 .....	38
4.6 本章小结 .....	41
<b>第五章 总结与展望 .....</b>	<b>42</b>
5.1 总结 .....	42
5.2 未来展望 .....	42
<b>参考文献 .....</b>	<b>44</b>
<b>攻读学位期间的成果 .....</b>	<b>58</b>
<b>致谢 .....</b>	<b>59</b>

# 第一章 绪论

## 1.1 研究背景和意义

优秀的开放域对话机器人（聊天机器人）应该有娱乐性和知识，同时让用户觉得自己能够被倾听。可能的谈话主题的广度和缺乏一个明确的目标使得很难定义一个培训优秀聊天机器人的路线图。尽管最近学术界和工业界在这方面取得了全面进展<sup>[3,4]</sup>，但聊天机器人仍然无法在进行对话的同时保持有趣、一致、准确和可靠，以及在谈论各种话题时保持行为端正（例如，不冒犯用户）。

传统的面向任务的对话系统依赖于槽填充和结构化模块（例如，Young 等<sup>[5]</sup>，Gao 等<sup>[6]</sup>，Jurafsky 等<sup>[7]</sup>），这些方法已经证明擅长在飞机票预订等狭窄领域开发可用的商业系统。然而，它们仅限于接受培训的领域，无法推广到新领域或开放聊天设置，因为这需要对许多模块或技能进行编码，以及在它们之间切换的管理系统。另一方面，基于神经网络的端到端的方法提供了适应任意宽的新领域而无需额外人工的可能，但尚未达到其全部潜力。端到端训练的深度架构在许多其他领域都非常成功，例如语音识别<sup>[8,9]</sup>，计算机视觉<sup>[10]</sup>，和机器翻译<sup>[11,12]</sup>。因此，研究界正在大力投资改进对话的端到端模型<sup>[3,4,13]</sup>，希望取得类似的成功。为了提升用户的体验，聊天机器人需要具备一些关键的对话理解能力，比如，聊天机器人应该识别说话者情感，能够理解对话语义，以及能够理解并正确处理对话中的不安全行为。

**情感**是人类固有的，因此情感理解是人工智能的关键部分。对话情绪识别作为自然语言处理的重要研究方向，由于具有挖掘意见的能力，近些年来越来越受欢迎，并且如今在 Facebook、Youtube、Reddit、Twitter 等平台上有着大量公开可用的对话数据可以用于研究。此外，对话情绪识别对于产生情感意识的对话也很重要。为了满足这些需求，需要有效和可扩展的对话情绪识别算法。

**对话语义**是说话者意图表达的核心载体，理解对话语义的难点是对话中普遍存在的省略与指代，主要原因是人们为了简洁方便，倾向于使用不完整的话语来对话，这通常会省略或引用出现在对话上下文中的概念。具体来说，Su 等<sup>[14]</sup>，Pan 等<sup>[15]</sup>指出，省略和指代存在于超过 70% 的对话语句中，这会给对话模型带来额外的负担，因为他们必须识别出这些省略和指代才能正确理解对话。对话角色语义标注和对话重写是两个对话语义理解的自然语言处理任务，它们的模型能够帮助聊天机器人更好

地理解对话，进而生成本更好地与用户进行交谈。

**安全性**是人工智能的能力越来越强道路上必须改善的问题。随着在大规模语料库上预训练的基于 transformer 的语言模型的出现，生成式开放域聊天机器人越来越受到关注<sup>[3,16,17]</sup>。然而，由于对其不可控制和不可预测的输出的安全担忧，生成对话模型在现实世界中的部署仍然受到限制。例如，微软的 TwitterBot *Tay* 于 2016 年发布，但在其种族主义和有毒评论引起公众强烈反对后很快被召回<sup>[18]</sup>。直到现在，对话安全仍然是生成对话模型的致命弱点。如何让聊天机器人更好地理解对话中的不安全行为是急需解决的问题。

## 1.2 相关工作

### 1.2.1 对话情绪识别

对话情绪识别 (Emotion Recognition in Conversation, ERC) 一直是一个 NLP 领域长期的研究课题<sup>[19,20]</sup>。早期工作通过人工的语言或声学特征来解决 ERC<sup>[21,22]</sup>。随着深度学习模型在分类和序列建模任务中的主导地位不断提高<sup>[23-25]</sup>，最近的 ERC 研究基于深度学习，深度学习可以进一步分为三种主要类型：基于 RNN 的模型、基于 GCN 的模型和基于 Transformers 的模型。基于 RNN 的模型在过去几年中得到了很好的探索。Poria 等<sup>[26]</sup> 首先使用递归神经网络 (RNN) 对 ERC 的对话上下文进行建模<sup>[27]</sup>。Hazarika 等<sup>[28]</sup> 考虑了说话人的信息，并且 Hazarika 等<sup>[29]</sup> 首先模拟了说话人之间的依赖关系。Majumder 等<sup>[30]</sup> 跟踪说话者的状态，他们的方法可以扩展到多方对话。Lu 等<sup>[31]</sup> 提出了一种基于 RNN 的迭代情感交互网络来显式建模话语之间的情感交互。Ghosal 等<sup>[32]</sup> 和 Sheng 等<sup>[33]</sup> 采用关系图卷积网络 (GCN)<sup>[34]</sup> 对 ERC 进行建模，其中整个对话被视为有向图，他们采用图卷积运算来捕获之间的依赖关系顶点（话语）。但是，将对话转换为图形会丢失原始对话的时间属性。由于 Transformers<sup>[25]</sup> 出色的表征能力，一些研究人员将其应用于 ERC 并取得了良好的结果<sup>[35,36]</sup>。最近，Ghosal 等<sup>[37]</sup> 将从预训练的常识转换器 COMET<sup>[38]</sup> 中提取的常识知识整合到 RNN 中，并在几个公共 ERC 数据集上获得了良好的结果。然而，上述模型都没有考虑上下文缺失或上下文冗余问题。

### 1.2.2 自训练

自训练<sup>[39-42]</sup>是一个经典的半监督学习框架<sup>[43]</sup>近年来被广泛探索。自训练的总体思路是采用训练好的模型对容易获取的未标记数据进行伪标记，并使用它们来扩充训练数据以迭代地重新训练模型。该范式在各种任务中显示出良好的效果：包括文本分类<sup>[44,45]</sup>、图像分类<sup>[46,47]</sup>、机器翻译<sup>[48]</sup>和模型蒸馏<sup>[49]</sup>。协同训练<sup>[50]</sup>和三重训练<sup>[51]</sup>是与自训练类似的迭代训练框架，但具有不同数量的模型或考虑训练了数据的不同视图，两者都在 NLP 领域得到了广泛采用<sup>[52-58]</sup>。这些框架旨在通过在一项任务上训练多个模型来提高性能，而不会利用相关任务的监督信号。

### 1.2.3 多任务学习

多任务学习<sup>[59,60]</sup>旨在其他相关任务的帮助下提高一个任务的学习性能，其中有两块工作与我们的相关：(1) 半监督多任务学习<sup>[61,62]</sup>结合了半监督学习和多任务学习。Liu 等<sup>[61]</sup>通过随机游走利用未标记数据，并使用任务聚类方法进行多任务学习。Li 等<sup>[62]</sup>将主动学习<sup>[63]</sup>与 Liu 等<sup>[61]</sup>中的模型相结合，以检索最能提供标签信息的数据。尽管这些工作试图利用未标记的数据来增强多任务学习，但我们的工作与它们的不同之处在于我们通过任务之间结合监督信号以选择高质量的伪标签来更新模型，这是一个迭代训练过程，无需额外的人工。(2) 任务分组<sup>[64-66]</sup>旨在找到相关任务组，并对每组任务采用多任务学习，每组一个模型。我们的工作重点是训练单任务模型，但任务分组技术可用于寻找可能的相近任务。

### 1.2.4 对话语义角色标注

对话角色语义标注 (Conversational Semantic Role Labeling, CSRL) 是一项预测对话上下文中谓词语义角色的任务。图 1-1 显示了一个 3 轮的中文 CSRL 的例子，其中像“雪宝”是第二轮中第二个谓词“喜欢”的“A1”谓元，这样的关系明确指出了核心的主谓宾关系（也是用“喜欢”来表达的细粒度情绪）。然而，传统的语义角色标注只能作用于一个句子，因此可能无法捕获对话语句之间的关键信息。例如，图 1-1 中第二个句子中的谓词“看了”的两个谓元“A0”和“AM-TMP”在传统语义角色标注中可能会被漏掉，因为这些谓元是存在于对话中的其他句子的。另外，预测第三个句子中的谓词“喜欢”和“雪宝”之间的关系是很有挑战性的，因为这同时需要知道“它”是“喜欢”的“A1”，以及“它”是“雪宝”的代词（指代消解）。

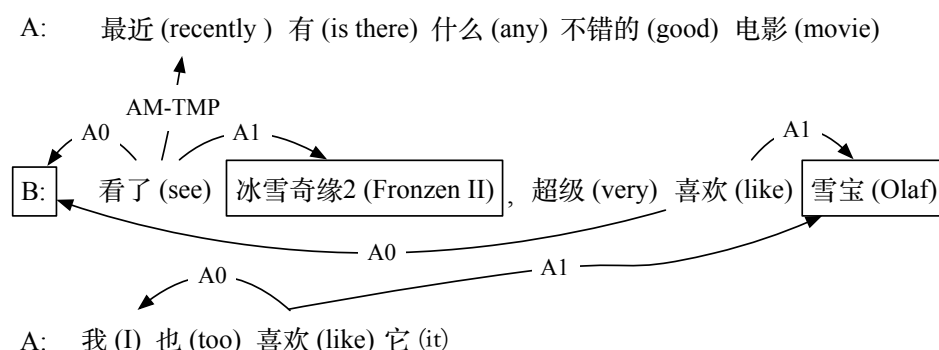


图 1-1 对语义角色标注的示例。这个涵盖了所有核心关系，而传统的语义标注只能覆盖用黑色箭头表示的关系。一条斜线表示共指关系。

Wu 等<sup>[67]</sup> 利用关系图神经网络<sup>[34]</sup> 对说话者和谓词依赖性进行建模，取得了一些有希望的结果。但是，CSRL 的当前数据集<sup>[68]</sup> 仅限于单域。需要新领域的高质量标记数据来增强更适用的 CSRL 模型。

### 1.2.5 对话重写

对话重写<sup>[14,15,69]</sup> 旨在将最新的对话话语重构为与原始话语在语义上等同的新话语，并且无需参考上下文即可理解。如表 1-1 所示，不完整的话语  $u_3$  省略了“上海”，并用代词“这样”引用了“经常阴天下雨”，通过将丢弃的信息显式重写进最新的话语，下游对话模型就只需要采用最后的话语。这样就可以大大减轻长距离推理的负担。

表 1-1 一个对话重写的示例，包括上下文话语 ( $u_1$  和  $u_2$ )、最新话语 ( $u_3$ ) 和重写话语 ( $u'_3$ )。

Turn	Utterance with Translation
$u_1$	上海最近天气怎么样? (How is the recent weather in Shanghai?)
$u_2$	最近经常阴天下雨。 (It is always raining recently.)
$u_3$	冬天就是 <b>这样</b> 。 (Winter is like <b>this</b> .)
$u'_3$	<b>上海</b> 冬天就是 <b>经常阴天下雨</b> 。 (It is <b>always raining</b> in winter <b>Shanghai</b> .)

对话重写通常被认为是一个序列到序列的问题，它会遇到很大的搜索空间问题<sup>[69,70]</sup>。为了解决这个问题，Hao 等<sup>[71]</sup> 将对话重写转换为序列标签，将重写话语

转换为从话语中删除符号或将对话历史中的跨度插入话语中。Jin 等<sup>[72]</sup>改进了<sup>[71]</sup>中的连续跨度问题,首先为每个符号和开槽规则生成多个跨度,然后用跨度替换固定数量的规则。然而,高质量的对话重写训练数据仍然是缺乏的。

### 1.2.6 对话安全数据集

近年来构建了关于带有不同形式标注的对话安全的数据集。对于不安全检测, Qian 等<sup>[73]</sup>、Xu 等<sup>[74]</sup>、Baheti 等<sup>[75]</sup>、Ung 等<sup>[76]</sup>和 Sun 等<sup>[77]</sup>在他们提出的对话数据集中提供了话语级二类安全标签。Baheti 等<sup>[75]</sup>注释了同一对话中每个话语的立场 (*stance*) 以间接帮助不安全检测。为了引导对话避免不安全的失败, Qian 等<sup>[73]</sup>和 Ung 等<sup>[76]</sup>分别从第三方或对话伙伴提供以自然语言表示的干预 (*intervention*) 和反馈 (*feedback*) 来避免话语中不安全的发生。Ung 等<sup>[76]</sup>进一步要求标注者给出优雅的响应以确认 *feedback* 并将对话引入可接受且文明的轨迹,聊天机器人可以从中学学习如何从不安全行为中恢复。然而,据我们所知,目前还没有带有不安全跨度和上下文相关安全替代响应的数据集。

### 1.2.7 有毒行为的缓解

为了检测不安全的内容,基于 Transformers<sup>[78,79]</sup>的分类器是主要的方法,因为它们具有很强的表示能力,一些数据集<sup>[80,81]</sup>可以作为主要资源用于训练强大的毒性检测器。更精细的毒性检测,即提取毒性跨度或短语,可以看作是序列标注<sup>[82]</sup>任务。对于文本去毒, Santos 等<sup>[83]</sup>和 Laugier 等<sup>[84]</sup>训练了一个编码器-解码器模型,将有毒话语重写为无毒话语。Dathathri 等<sup>[85]</sup>和 Krause 等<sup>[86]</sup>利用鉴别器来约束语言模型,让它的生成无毒,并且 Dale 等<sup>[87]</sup>利用转述模型改进了 Krause 等<sup>[86]</sup>的方法。Ouyang 等<sup>[88]</sup>和 Glaese 等<sup>[89]</sup>通过强化学习注入人类反馈,使生成的响应更有用且无害。

## 1.3 章节和内容安排

本文共分为五个章节,各章节具体安排如下:

第一章:绪论。本章介绍本文中每个工作的任务背景和意义,并阐述一下与工作相关的有关文献的进展和内容,以及存在的问题。

第二章:基于变长上下文的对话情绪识别。本章提出了一种新的对话情绪分析方

法，能够从可变长度的上下文中识别说话者的情绪。本章的实验和消融研究表明，提出的方法可以有效缓解对话情绪分析中的上下文缺失和上下文冗余问题，同时在三个公共数据集上实现具有竞争力的性能。

第三章：基于友邻训练的对话理解。本章提出了友邻训练，这是第一个跨任务自训练框架，它利用友邻任务的监督来更好地选择伪标签。此外，本章在对话语义角色标注和对话重写之间实现了友邻训练。领域泛化和少样本学习场景的实验证明了友邻训练的前景，它大幅度优于之前的经典或最先进的半监督方法。

第四章：基于 SafeConv 的对话不安全行为理解。本章提出了 SafeConv，第一个具有对话安全综合标注的大规模数据集。SafeConv 标注了不安全跨度以回答为什么话语不安全，并提供安全的替代响应来替换不安全的响应来更好地理解对话中的不安全行为。实验和分析表明，SafeConv 有效地推进了对话不安全行为的解释和解毒。

第五章：总结全文并且基于现有的工作给出未来展望。



## 第二章 基于变长上下文的对话情绪识别

本章专注于提升聊天机器人识别说话者情绪的能力，即对话情绪识别 (Emotion Recognition in Conversation, ERC)。现有的 ERC 方法使用固定的上下文窗口信息来识别说话者的情绪，这其中存在两个可能的问题：关键上下文信息的缺乏或冗余上下文信息的干扰，使得聊天机器人对说话者的判断不准确。本章探索如何利用可变上下文信息来解决以上两个问题。具体而言：2.1节通过用具体的例子阐释以上两个问题来引出本章内容；2.2节详细描述了能够根据变长上下文信息来进行 ERC 的方法；然后 2.3节利用实验对提出的方法进行验证，最后 2.4节总结本章内容。

### 2.1 引言

对话中的情绪识别是根据先前的上下文和当前的话语来预测对话者在对话中的情绪的任务。演讲者的情绪是其心理状态的关键指标和影响因素。ERC 的重大技术突破推动了医疗保健、消费品和金融服务等领域的应用发展<sup>[19-22,90-92]</sup>。

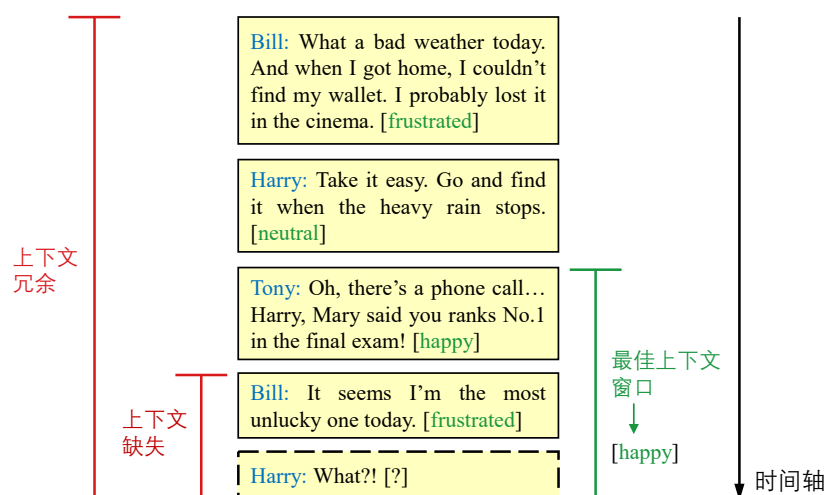


图 2-1 一个多方对话 ERC 示例。*Harry* 情绪的理想上下文窗口将恰好包括两个前面的话语，因为其中 *Tony* 提供了 *Harry* 快乐的证据。*Tony* 之前的话语是多余的，因为它们与当前的对话无关。

图 2-1 显示了 ERC 的一个示例。现有方法<sup>[26,28-30,32,35,37,93,94]</sup>只考虑一个固定的上下文窗口（即前面的话语的数量），这可能会遇到两个问题：(1) 上下文稀疏——由于窗口小而缺乏上下文；或 (2) 上下文冗余——由于上下文窗口过大，包含来自不相关话语的冗余上下文。例如，在图 2-1 中，正确预测当前话语（在虚线框中）的情绪需要至少两个先前的话语。然而，包括任何更多的前面的话语是没有帮助的。因此，选

择正确的上下文窗口对 ERC 至关重要。在这种情况下，知道当前说话者是 *Harry* 有利于选择正确的上下文窗口，因为前面的话语之一明确提到 *Harry*，表明它可能包含与当前话语相关的信息。也就是说，说话人依赖是确定正确上下文窗口的关键指标。

为了探索可变长度上下文的好处，本章提出了一种新的 ERC 方法：在对话中，话语之间的时序依赖和说话者依赖对于对话理解都至关重要<sup>[95]</sup>，其中说话者依赖可以进一步分类为说话人内部和说话人之间的依赖关系<sup>[96]</sup>。首先，通过一个基于注意力的话语编码器和两个说话者感知单元对上述依赖关系进行建模，以生成对话上下文表示，其中，内部和说话人之间的依赖关系被显式建模以帮助检测理想的上下文窗口。接下来，一个 top-k 归一化层基于降维后的上下文表示生成 top-k 最佳上下文窗口及其概率权重。最后，通过软性地利用 top-k 最佳上下文窗口来预测当前话语的情绪。

实验结果表明，该方法在三个公共对话数据集上取得了具有竞争力的性能：在双方对话数据集 IEMOCAP<sup>[97]</sup> 和 DailyDialog<sup>[98]</sup> 上分别得到了 66.35% 和 61.22% 的 F1，以及在多方对话数据集 EmoryNLP<sup>[99]</sup> 上得到 38.93% 的 F1。广泛的消融研究证明了每个组件在该方法中的贡献以及使用可变长度上下文的必要性。

## 2.2 方法

### 2.2.1 任务定义

一次对话由  $n$  个按时间顺序排列的话语  $\{x_1, \dots, x_t, \dots, x_n\}$  及其说话者  $\{s_1, \dots, s_t, \dots, s_n\}$  组成。每个  $x_t$  都是一个单词序列。在时间步  $t$ ，ERC 的目标是在给定当前和之前的话语及其说话者的情况下，为说话者  $s_t$  找出最可能的情感标签  $\hat{y}_t$ ：

$$\hat{y}_t = \operatorname{argmax} p(y_t | x_{1:t}, s_{1:t}),$$

这里  $x_{1:t} = \{x_1, \dots, x_t\}$  并且  $s_{1:t} = \{s_1, \dots, s_t\}$ 。

### 2.2.2 方法

如图 2-2 所示，该方法由以下模块组成：(1) 一种话语编码器，用于编码对话话语之间的时序依赖；(2) 两个说话人感知单元，明确编码说话人内部和说话人之间的依

赖关系，以帮助检测理想的上下文窗口；(3) 一个多层感知器和一个 top-k 归一化层，生成不同的上下文窗口的分布，从中确定 top-k 最佳上下文窗口及其相应的权重；(4) 一个预测模块，它从具有不同概率权重的前 k 个最佳上下文窗口生成情绪分布。

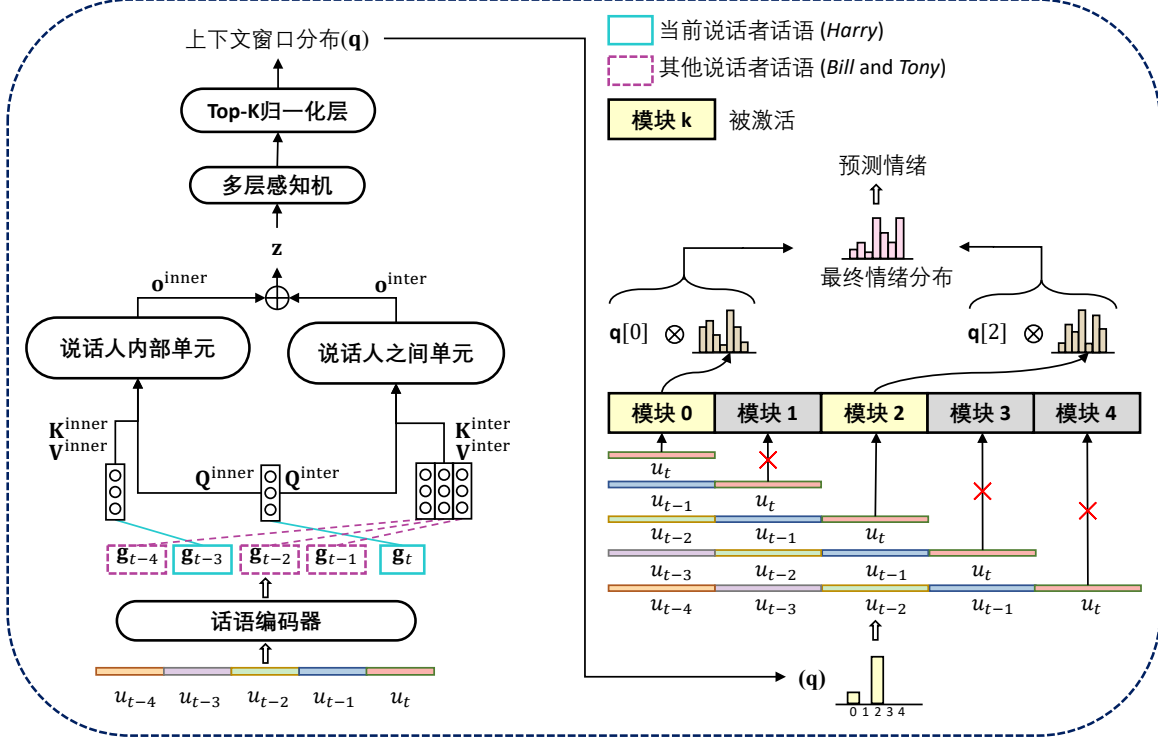


图 2-2 方法的总体架构。图 2-1 中的实例用作输入。Step1: 话语编码器对话语之间的时序依赖进行编码，并输出话语级表示。第 2 步: 说话人感知单元捕获说话人内部和说话人之间的依赖关系形成向量  $z$ 。Step3: 上下文窗口分布  $q$  由 MLP 和 top-k 归一化层生成（这里使用 top-2 进行说明）。Step4: 以上下文窗口分布为条件进行情绪预测。省略了特殊符号 [CLS]。

**话语编码器** 话语编码器的输入是一个带有说话人信息的符号序列。在时间步  $t$ ，通过将说话人信息（即说话人的姓名）添加到每个话语之前生成输入序列，然后将直到时间步  $t$  的话语连接成单个标记序列。说话者的姓名和话语由特殊的 [SEP] 标记分隔。

输入序列被送入 RoBERTa<sup>[79]</sup> 的基础版本以编码话语之间的时序依赖并为每个话语生成上下文表示：

$$u_i = s_i \oplus [\text{SEP}] \oplus x_i,$$

$$[g_1, \dots, g_t] = \text{RoBERTa}(\oplus_{i=1}^t u_i),$$

其中  $g_i$  表示时间步长  $i$  的话语的上下文表示，对应于  $u_i$  的第一个符号的 RoBERTa 输出。本章考虑最多  $M$  个先前时间步长的上下文窗口，编码器输出向量序列  $[g_{t-M}, \dots, g_t]$ ，其中  $g_i \in \mathbb{R}^d$ 。

**说话者感知单位** 本章提出的方法结合了说话人的依赖来指导理想上下文窗口的检测。具体来说，提出的方法包含了两个说话人感知单元，来明确捕获说话人内部和说话人之间的依赖关系。这两个单元具有相同的基于注意力的结构，但它们不共享参数。首先将话语上下文表示  $[\mathbf{g}_{t-M}, \dots, \mathbf{g}_{t-1}]$  分成两个子集  $\mathbf{G}^{\text{inner}}$  和  $\mathbf{G}^{\text{inter}}$ ，区分依据是它们对应的说话人是否与当前说话人相同。然后将相应的子集  $\mathbf{G}$  和  $\mathbf{g}_t$  输入对应的说话人感知单元，并应用多头注意力和层归一化<sup>[25]</sup> 来合并说话人依赖：

$$\begin{aligned}\mathbf{o} &= \text{LayerNorm}(\mathbf{c} + \mathbf{g}_t), \\ \mathbf{c} &= \mathbf{W}^O \cdot \text{Concat}(\text{head}_1, \dots, \text{head}_h), \\ \text{head}_i &= \text{Attention}(\mathbf{W}_i^Q \mathbf{g}_t, \mathbf{W}_i^K \mathbf{G}, \mathbf{W}_i^V \mathbf{G}),\end{aligned}$$

其中  $(\mathbf{W}^Q, \mathbf{W}^K, \mathbf{W}^V) \in \mathbb{R}^{d_k \times d}$  和  $\mathbf{W}^O \in \mathbb{R}^{d \times d}$  是说话人特定的参数， $d_k = \frac{d}{h}$  是每个注意力头的维度。注意力（Attention）定义同 Vaswani 等<sup>[25]</sup>：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \mathbf{V} \cdot \text{softmax}\left(\frac{\mathbf{K}^T \mathbf{Q}}{\sqrt{d_k}}\right).$$

接着将两个说话人感知单元的输出  $\mathbf{o}^{\text{inner}}$  和  $\mathbf{o}^{\text{inter}}$  拼接作为当前对话的上下文表示：

$$\mathbf{z} = [\mathbf{o}^{\text{inner}}; \mathbf{o}^{\text{inter}}] \in \mathbb{R}^{2d}, \quad (2.1)$$

$\mathbf{z}$  编码了输入话语和说话者的信息以及它们的依赖关系。

**上下文窗口分布** 接下来利用  $\mathbf{z}$  生成 0 到  $M$  上下文窗口对应的概率分布。具体而言是通过以下方式完成的：(1) 一个多层感知器，它将  $\mathbf{z}$  映射到多个上下文窗口，以及 (2) 一个 top-k 归一化层，它在上下文窗口上生成分布。具体来说，首先将  $\mathbf{z}$  送入一个双层 MLP 以获得上下文窗口的分数  $\mathbf{s}$ ：

$$\begin{aligned}\mathbf{h} &= \text{ReLU}(\mathbf{W}_h \mathbf{z} + \mathbf{b}_h) \in \mathbb{R}^{d_h}, \\ \mathbf{s} &= \mathbf{W}_s \mathbf{h} + \mathbf{b}_s \in \mathbb{R}^{M+1},\end{aligned}$$

其中  $\mathbf{W}_h \in \mathbb{R}^{d_h \times 2d}$ ， $\mathbf{W}_s \in \mathbb{R}^{(M+1) \times d_h}$ ， $\mathbf{b}_h$  和  $\mathbf{b}_s$  是参数， $d_h$  是隐藏层的维度。然后，根据  $\mathbf{s}$  中的值构造  $\mathbf{s}$  的 top- $K$  掩码，记为  $\mathbf{m}$ 。如果  $\mathbf{s}[i]$  在  $\mathbf{s}$  中， $\mathbf{m}[i] = 0$ ，否则  $\mathbf{m}[i] = -\infty$ ，其中  $K$  是一个超参数。接着使用 softmax 对掩蔽的  $\mathbf{s}$  进行归一化，以生成当前话语的

上下文窗口分布  $\mathbf{q}$ :

$$\mathbf{q} = \text{softmax}(\mathbf{s} + \mathbf{m}) \in \mathbb{R}^{M+1}. \quad (2.2)$$

**基于 top- $K$  最佳上下文窗口的情绪预测** 该方法没有使用  $\mathbf{q}$  中概率最高的上下文窗口来预测情绪，而是使用  $\mathbf{q}$  作为软标签，并在预测中利用所有 top- $K$  上下文窗口。

如图 2-2 所示，预测模块包含从 0 到  $M$  的  $M+1$  个上下文模块，其中模块  $i$  对应于上下文窗口  $i$  的使用。每个的输入，在其前面有一个 [CLS]，由特定于模块的上下文编码器与话语编码器具有相同的架构。之后对 [CLS],  $\mathbf{g}_{[\text{CLS}]}^i \in \mathbb{R}^d$  的编码器输出使用特定领域的线性分类器，以计算给定上下文窗口  $i$  的情感标签分布  $\mathbf{p}^i$ :

$$\mathbf{p}^i = \text{softmax}(\mathbf{W}^i \mathbf{g}_{[\text{CLS}]}^i + \mathbf{b}^i) \in \mathbb{R}^c,$$

其中  $\mathbf{W}^i \in \mathbb{R}^{c \times d}$  和  $\mathbf{b}^i$  是参数， $c$  是情感类别的数量。

最终的情感标签分布  $\hat{\mathbf{p}}$  结合了 top- $K$  上下文窗口分布和给定不同上下文窗口的情感标签分布:

$$\hat{\mathbf{p}} = \sum_{i \in \text{top-}K} \mathbf{q}[i] \mathbf{p}^i \in \mathbb{R}^c, \quad (2.3)$$

### 2.2.3 训练和预测

对于训练，优化每个小批量对话样本  $\mathcal{B}$  的交叉熵损失  $\mathcal{L}$ :

$$\mathcal{L} = \sum_{i=1}^{|\mathcal{B}|} \sum_{j=1}^{|\mathcal{B}_i|} -\log \hat{\mathbf{p}}^{ij}[y_{ij}],$$

其中  $|\mathcal{B}|$  表示对话的数量， $|\mathcal{B}_i|$  表示对话  $\mathcal{B}_i$  中话语的数量， $y_{ij}$  是对话  $\mathcal{B}_i$  和  $\hat{\mathbf{p}}^{ij}$  中话语  $x_j$  的黄金情感标签索引是相应的预测标签分布。

在测试时，根据等式 2.3 中的最终情感标签分布  $\hat{\mathbf{p}}$  选择情感标签  $\hat{y}$ :

$$\hat{y} = \underset{i}{\text{argmax}} \hat{\mathbf{p}}[i].$$

## 2.3 实验

### 2.3.1 设置

本章实验将新方法与经典方法 DialogueRNN<sup>[30]</sup>、DialogueGCN<sup>[32]</sup> 以及最新的方法 RoBERTa-BASE<sup>[79]</sup>、KET<sup>[35]</sup> 和 COSMIC<sup>[37]</sup> 在三个公开数据集进行了比较：两个双方对话数据集 IEMOCAP<sup>[97]</sup>、DailyDialog<sup>[98]</sup> 和一个多方对话数据集 EmoryNLP<sup>[99]</sup>。这些数据集在对话者的数量、对话场景和情感标签上有所不同。IEMOCAP<sup>[97]</sup> 是一个多模态两方对话数据集，对话中的每个话语都用情绪标签 *angry*、*sad*、*happy*、*excited*、*frustrated* 或 *neutral* 进行注释；DailyDialog<sup>[98]</sup> 是一个单模态两方对话数据集，它涵盖了关于日常生活的各种主题，注释的情绪标签有 *anger*、*disgust*、*fear*、*joy*、*sadness*、*surprise* 和 *neutral*；EmoryNLP<sup>[99]</sup> 是一个单模态多方对话数据集，它也是从 *Friends* 电视剧注释而来的，具有七个情绪标签：*sad*、*scared*、*joyful*、*mad*、*powerful*、*peaceful* 和 *neutral*。实验中最考虑 7 个 ( $M = 7$ ) 之前的回合（即 8 个上下文模块）。上下文模块在数据集上进行了微调，并且它们的参数在训练期间被冻结。对于数据集 IEMOCAP、DailyDialog 和 EmoryNLP，各自的参数  $K = 4, 3, 5$ 。此外，对于说话人感知单元中的多头注意力，头的维度设置为 192，头数量设置为 4，dropout 设置为 0.1。对于说话人感知单元之后的 MLP，使用 256 的隐藏层大小。为了优化整个网络，实验中使用 AdamW 优化器<sup>[100]</sup> 和线性调度器来控制学习率的预热和衰减过程。具体来说，将预热比设置为 0.06，将峰值学习率设置为  $2e-5$ ，并将最大训练周期设置为 5。使用 32 的批量大小和 0.01 的 L2 权重衰减。实验中根据开发集的性能选择超参数。对于 DailyDialog，使用排除 *neutral* 类的微平均 F1 分数，*neutral* 类占整个数据集的百分比高达 83%；对于其他两个数据集，计算加权宏 F1 分数<sup>[35,96]</sup>。我们在五个随机种子下进行相同实验并报告平均结果。

### 2.3.2 主要结果

主要结果报告在表 2-1 中。我们提出的方法在数据集 IEMOCAP、DailyDialog 和 EmoryNLP 上达到了最佳性能，分别超过了最佳的基线方法 COSMIC 1.07%、2.74% 和 0.82% F1 分数。该方法优于 COSMIC 的性能要归功于对可变长度上下文的考虑。此外，与 COSMIC 不同，该方法不依赖于外部知识。对于 IEMOCAP，我们的方法甚至在 F1 分数上以显著优势超过多模态模型 DialogueRNN，这表明 1) ERC 中的文本

信息仍然需要更有效地利用，以及 2) 该方法通过减轻上下文稀缺性来有效利用文本信息和上下文冗余问题。

表 2-1 主要结果。最好的 F1 分数以粗体突出显示。- 表示未报告的结果。CSK 是 commonsense knowledge (常识知识) 的缩写。★ 表示实验中得到的结果。

方法	IEMOCAP	DailyDialog	EmoryNLP
DialogueRNN <sup>[30]</sup>	62.75	50.65	31.70
DialogueGCN <sup>[32]</sup>	64.18	-	-
RoBERTa-BASE★ <sup>[79]</sup>	62.46	58.41	35.44
KET <sup>[35]</sup>	59.56	53.37	34.39
COSMIC <sup>[37]</sup>	65.28	58.48	38.11
COSMIC without CSK	63.05	56.16	37.10
Ours★	<b>66.35</b> (±0.21)	<b>61.22</b> (±0.16)	<b>38.93</b> (±0.23)

### 2.3.3 消融实验

为了揭示我们提出的方法中不同组件的贡献，我们对主要组件进行了消融实验：分别是说话人感知单元和上下文窗口分布的生成方法。

**说话人感知单元** 将说话人感知单元与以下说话人依赖建模方法进行比较：

- ***N-Unit***: *N-Unit* 与说话人感知单元共享相同的结构。与说话者感知单元不同的是，其输入的键和值都是先前的话语表示，而不管它们在说话者内部和说话者之间的关系。因此 *N-Unit* 是非说话人感知的。
- ***S-Unit***: *S-Unit* 将指示每个话语的说话者的独热向量连接到话语表示，并执行与 *N-Unit* 相同的操作。
- ***GCNs***: 来自 Ghosal 等<sup>[32]</sup> 的方法，其中用多个图形卷积层捕获说话人的依赖。节点是话语，边权重是通过基于相似性的注意模块获得的。在其后添加一个最大池化层和一个线性层以获得向量  $\mathbf{z}$ 。GCNs 的输入是话语编码器的输出。

表 2-2 显示了比较结果。我们提出的方法优于 *S-Unit* 的性能，因为我们的方法对说话人内部和说话人间依赖关系进行了显式建模。*S-Unit* 超过 *N-Unit*，表明说话人信息在 ERC 的上下文建模中不可或缺。此外，说话人感知单元在二元数据集 (IEMOCAP 和 DailyDialog) 上的 F1 分数比其他三种方法中最好的方法高 0.33% 和 0.72%，低于多方数据集 (EmoryNLP) 上的 0.85%。这是因为多方对话中比二元对话更复杂的说

话者依赖。当更多说话者参与对话时，我们的方法更善于捕捉说话者的依赖。

表 2-2 在测试集上说话人感知单元消融的结果。

方法	IEMOCAP	DailyDialog	EmoryNLP
<i>N-Unit</i>	64.49	59.00	36.15
<i>S-Unit</i>	65.95	60.50	36.60
<i>GCNs</i>	66.02	60.14	38.08
<b>Ours</b>	<b>66.35</b>	<b>61.22</b>	<b>38.93</b>

**上下文窗口分布的生成方法** 上下文窗口分布  $\mathbf{q}$  (见等式2.2) 控制上下文模块的激活并作为注意力权重合并输出分布。在我们的方法中，采用 MLP 和 top-k 归一化层来生成  $\mathbf{q}$ 。除此之外，尝试了  $\mathbf{q}$  的其他几种生成方法，并将它们与我们的方法进行了比较。基于  $\mathbf{q}$  的两个函数，上下文模块的 top-k 激活和输出分布加权，我们比较了以下的方法变体：

- **All-Soft**: 我们方法中的 top-k 归一化层被 softmax 层替换以获得  $\mathbf{q}$ ，这意味着所有的  $M + 1$  上下文模块始终被激活，并且上下文字段的输出分布由注意力权重合并。
- **Topk-Hard**: 在 top-k 归一化层之后， $\mathbf{q}$  中的  $K$  个非零概率被设置为  $\frac{1}{K}$ ，也就是说  $K$  激活的上下文模块的输出分布具有相同的权重。
- **All-Hard**: 不管时序和说话人的依赖如何， $\mathbf{q}$  中的所有概率都设置为  $\frac{1}{M+1}$ ，这意味着所有  $M + 1$  上下文模块始终被激活，并且上下文模块的输出分布具有相同的权重。
- **Topk-Soft**: 我们提出的方法。

测试集的 F1 分数如表 2-3 所示。与 *All-Hard* 相比，*All-Soft* 仅在 EmoryNLP 上具有更好的性能。这是因为这样一个事实，即正确上下文窗口的注意力权重并不明显大于不正确上下文窗口的注意力权重。因此，在我们的方法中直接禁用不正确的上下文字段比激活它们并给予它们较少的注意力权重更合理。针对上述分析，*Topk-Hard* 几乎在所有数据集中都优于 *All-Hard*，再次表明应该避免激活不正确的上下文字段。top-k 归一化层提高了  $K$  激活上下文字段的注意力权重，这表明 *Topk-Soft* 优于 *Topk-Hard*。



表 2-3 三个数据集测试集上上下文窗口分布生成方法的消融结果。

方法	IEMOCAP	DailyDialog	EmoryNLP
<i>All-Soft</i>	65.24	60.51	37.87
<i>Topk-Hard</i>	65.75	60.22	38.23
<i>All-Hard</i>	65.42	60.56	37.11
<i>Topk-Soft</i>	<b>66.35</b>	<b>61.22</b>	<b>38.93</b>

### 2.3.4 案例研究

在表 2-4 中的第一个案例中，具有固定比较大的上下文窗口的 RoBERTa-BASE 产生错误答案 *anger* 而考虑可变长度上下文的方法产生了正确的答案：Monica 的情绪为 *surprise*。当  $K = 2$  时，我们的方法选择上下文窗口为 0 和 1 进行情绪预测，阻止前两个话语中的冗余上下文。在第二种情况下，具有固定上下文窗口为 1 的 RoBERTa-BASE 对 Rachel 的情绪产生错误答案：sad，因为 RoBERTa-BASE 失去了关于 Rachel 抱怨的关键上下文：前两句中哭泣的婴儿。并且，当  $K = 2$  时，我们的方法认为最佳上下文窗口是 3 和 4，避免丢失关键上下文并产生正确答案 *anger*。

表 2-4 来自 EmoryNLP 的测试实例。比较了 RoBERTa-BASE (RoB) 与新方法的结果。

说话者	话语	RoB	Ours
<b>样例 1</b>			
Chandler	Okay, is this lamp in the same place?	-	-
Ross	Who cares? I repel women	-	-
Chandler	No-no-no-no!!! You can 't come in here! R-r-r-r-Ross is naked.	-	-
Monica	What?!	anger	surprise
<b>样例 2</b>			
Rachel	Oh no just stopped to throw up a little bit.	-	-
Rachel	Oh come on, what am I gonna do, its been hours and it won' t stop crying.	-	-
Monica	Umm, she Rach, not it, she.	-	-
Rachel	Yeah, I' m not so sure.	-	-
Rachel	Oh my god, I am losing my mind.	sad	anger

## 2.4 本章小结

为了缓解对话情绪分析中的上下文稀疏和上下文冗余问题，本章提出了一种新的对话情绪分析方法，能够从可变长度的上下文中识别说话者的情绪。精心设计的实验和消融研究证明了该方法的有效性。未来，我们倾向于通过外部知识或辅助任务来改进上下文窗口分布。此外，我们将继续探索检测适当上下文窗口的机制。

## 第三章 基于友邻训练的对话语义理解

本章专注于提升聊天机器人理解对话语义的能力。对话语义角色标注和对话重写是两个让模型理解对话语义的任务，但是这两个任务目前缺乏高质量的训练数据。本章将自训练和多任务结合，提出了一个新的半监督学习框架来利用大规模无标注数据生成高质量的伪标签，用于训练模型。具体而言，3.1节用具体的例子阐释了新框架的主要思想并引出全文；3.2节详细介绍了新框架的原理；3.3节介绍了如何在对话语义角色标注和对话重写两个任务上使用新框架；3.4节利用实验证明了新框架的有效性；最后3.5节总结本章内容。

### 3.1 引言

许多不同的机器学习算法，例如自监督学习<sup>[78,101,102]</sup>，半监督学习 (Yang 等<sup>[60]</sup>) 和弱监督学习<sup>[103]</sup>，旨在使用无标注的数据来提高模型性能。由于目前互联网上有大量可用的无标注数据，这些方法最近引起了研究者很大的兴趣。自训练<sup>[39]</sup> 是一种半监督学习方法，旨在通过伪标签来提升模型性能，并已成功应用于计算机视觉<sup>[42,104]</sup>，自然语言处理<sup>[105,106]</sup>，和其他领域<sup>[107,108]</sup>。

自训练的主要挑战是如何选择高质量的伪标签。当前的自训练算法在评估伪标签的质量时主要关注单个任务并会因为受到噪声数据的影响<sup>[109]</sup>。本章工作的动机是不同任务的学习目标代表输入的不同属性，并且一些属性在任务之间共享，可以用作从一个任务到另一个任务的监督信号。这些属性包括依存句法分析和成分句法分析中的某些跨度边界，以及情感分析和情绪识别中的某些情感极性。两个对话理解任务，对话语义角色标注 (Conversational Semantic Role Labeling, CSRL) 和对话重写 (Dialogue Rewriting, DR) 也是这样的一对任务，它们具有共指和零代词解析等共享属性。如图3-1所示，重写的话语产生对于谓词“喜欢”的参数的跨任务监督信号。本章利用来自友邻任务 (不同但相关的任务) 之间的跨任务监督信号作为评估伪标签质量的重要标准。

在这项工作中，本章提出友邻训练，第一个跨任务的自训练框架。与单任务自训练相比，友邻训练利用友邻任务的监督来更好地选择伪标签。为了实现这个目标，友邻训练框架中包含两个新颖的模块：(1) 翻译匹配器，它将每个实例的不同任务的

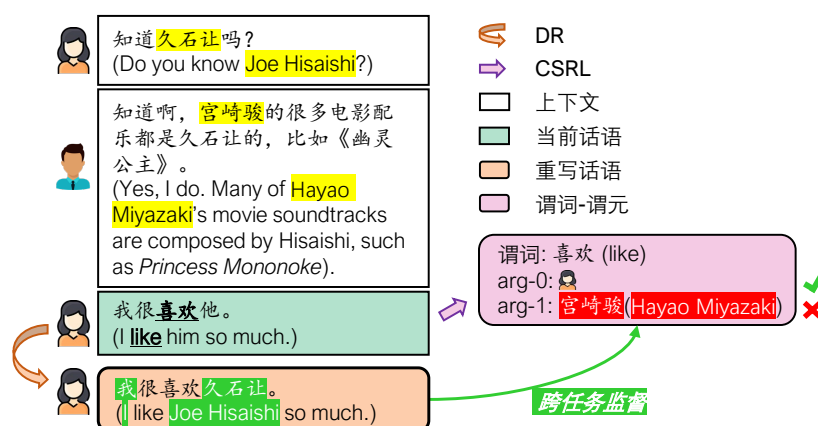


图 3-1 CSRL 解析器和 DR 系统在对话中的跨任务监督示例。在重写话语中的“久石让”对谓词“喜欢”的预测的 arg-1 产生了跨任务监督，同时“我”对预测的 arg-0 产生了跨任务监督。

伪标签映射到同一空间并计算匹配分数，代表来自不同任务的伪标签的跨任务匹配度；（2）增强（实例）选择器，它同时利用来自特定任务模型的伪标签的置信度和匹配分数来选择具有高质量伪标签的实例作为新的训练数据。本章选择 CSRL 和 DR 作为友邻任务来进行友邻训练的案例研究，并具体建模了在这两个任务之间实施友邻训练需要的翻译匹配器和增强选择器。域泛化和少样本学习的实验结果表明，友邻训练大大超过了一些经典和最先进的半监督学习算法。总的来说，本章的贡献包括：

- 提出友邻训练，这是第一个跨任务自训练框架，利用友邻任务的监督在迭代训练过程中更好地选择伪标签。
- 提供了 CSRL 和 DR 之间实施友邻训练的具体方法，包括一个新颖的翻译匹配器和一个新颖的增强选择器。
- CSRL 和 DR 的广泛实验证明了友邻训练的有效性，效果优于几个强基线方法，提升了模型理解对话中对话语义的能力。

## 3.2 友邻训练框架

### 3.2.1 自训练

经典的自我训练旨在通过使用一小部分标注数据和大量无标注的数据迭代地改进单个任务的模型。在每次迭代中，模型首先为无标注数据打上伪标签。随后，选择一组带有伪标签的实例进行训练，这些实例理想情况下应该具有有助于帮助模型泛化的信息。然后基于标签和伪标注数据上，最小化模型预测和标签的交叉熵以更新模

型：

$$L = \sum_{i=1}^N y_i \log \frac{y_i}{p_i} + \lambda \sum_{i=1}^{N'} y'_i \log \frac{y'_i}{p'_i}, \quad (3.1)$$

其中左边项是标记数据的损失，右边是未标记数据的损失，而  $\lambda$  是平衡它们的系数； $N(N')$  是实例数， $y(y')$  是标签， $p(p')$  是模型的输出概率。

自训练通常仅限于单项任务，但很多 NLP 任务是相关的。为一个任务训练的模型可以成为其他相关任务的好老师。本章通过引入小节3.2.2中介绍的两个新模块来探索自训练中的这种跨任务监督信号。

### 3.2.2 友邻训练

对于有两个任务的友邻训练<sup>1</sup>，有两个分别训练于数据集  $\mathcal{L}_a$  和  $\mathcal{L}_b$  的分类器  $f_a$  和  $f_b$ ，它们分别的期望准确率是  $\eta_a$  和  $\eta_b$ 。这两个数据集是独立创建的，两个任务的预测目标由一对翻译函数  $\mathcal{F}_a: \hat{Y}_a \rightarrow \Sigma$  和  $\mathcal{F}_b: \hat{Y}_b \rightarrow \Sigma$  产生关系，其中  $\Sigma$  是两个任务标签空间的子空间， $|\hat{Y}_a| \geq |\Sigma|, |\hat{Y}_b| \geq |\Sigma|$ 。我们规定翻译函数是一般的函数，产生一个具体翻译结果的期望概率是  $\epsilon_{\mathcal{F}} = \frac{1}{|\Sigma|}$ ，并且，翻译函数是决定性，总是将来自不同任务的正确的预测结果对应到相同的翻译结果。

在迭代步  $k$ ，两个分类器在无标注数据  $\mathcal{U}$  上进行预测，根据翻译函数的结果  $\phi_a(x) = \mathcal{F}_a(f_a(x))$  and  $\phi_b(x) = \mathcal{F}_b(f_b(x))$  和一些筛选指标，比如相似度，一些拥有伪标签的实例  $\mathcal{U}_{\mathcal{F}}^k$  被选择作为新的训练数据。如果相似度被作为筛选指标，分类器  $f_a$  在这些例子上产生错误预测的概率是

$$\begin{aligned} & \Pr_x[f_a(x) \neq f_a^*(x) | \phi_a(x) = \phi_b(x)] \\ &= 1 - \frac{\eta_a \Pr_x[\phi_a(x) = \phi_b(x) | f_a(x) = f_a^*(x)]}{\Pr_x[\phi_a(x) = \phi_b(x)]}, \end{aligned} \quad (3.2)$$

其中  $f^*$  是最优的分类器。

由于训练数据，标注准则，模型以及预测目标等的不同，两个分类器区别很大，所以两个分类器很大几率是相互独立的，在这个条件下，等式 3.2变成了

<sup>1</sup>本章专注于两个任务之间的友邻训练，但是，友邻训练可以很容易地扩展到两个以上的任务。

$$\begin{aligned}
& 1 - \frac{\eta_a(\eta_b + \epsilon_{\mathcal{F}}(1 - \eta_b))}{\Pr_x[\phi_a(x) = \phi_b(x)]} \\
& = 1 - \frac{Z}{Z + \eta_b \epsilon_{\mathcal{F}}(1 - \eta_a) + E},
\end{aligned} \tag{3.3}$$

其中  $Z = \eta_a(\eta_b + \epsilon_{\mathcal{F}}(1 - \eta_b))$ ,  $E = \epsilon_{\mathcal{F}}^2(1 - \eta_a)(1 - \eta_b)$ , 这表明选出实例的数量和由于错误的翻译结果产生的错正例的数量  $\eta_b \epsilon_{\mathcal{F}}(1 - \eta_a)$  以及匹配的负例的数量  $E$  是负相关的。当选择具有足够大的目标空间  $\Sigma$  的翻译函数的时候,  $\epsilon_{\mathcal{F}}$  能够被最小化, 这时如果两个分类器相符, 选择错例的几率接近于 0。同时也说明即使是  $1 - \eta_a$  很大, 即  $f_a$  表现很差, 如果共同空间很大, 选择错例的几率也能被控制得很小<sup>2</sup>。当两个分类器之间的依赖逐渐增强, 错例的概率同时也增加。当两个分类器完全依赖于对方的时候, 等式 3.2 变成了  $1 - \eta_a$ , 即经典的自训练框架。

基于这个公式, 需要两个额外的模块: (1) 一个将在不同任务上训练的两个模型的预测映射到同一空间并计算匹配分数的翻译匹配器; (2) 一个考虑到翻译预测的匹配分数和模型置信度的增强(实例)选择器, 它为分类器选择具有伪标签的实例。

**翻译匹配器** 给定两个友邻任务模型的预测  $f_a(x)$  和  $f_b(x)$ , 翻译匹配器  $\mathcal{M}$  利用翻译函数  $\mathcal{F}_a$  和  $\mathcal{F}_b$  得到翻译过的伪标签并且为这一对伪标签计算匹配分数  $m$ , 表示它们在翻译空间中的相似度:

$$m_{a,b} = \mathcal{M}(\mathcal{F}_a(f_a(x)), \mathcal{F}_b(f_b(x))), \tag{3.4}$$

最大的匹配度是 1, 匹配分数作为筛选高质量伪标签的指标。

**增强选择器** 除了伪标签相似性之外, 还可以从模型置信度中找到有关伪标签质量的其他信息, 来增强匹配分数。增强选择器同时考虑了来自任务模型的伪标签的置信度, 记作  $\{c_a, c_b\}$  和匹配分数:

$$q_{\tau} = \mathcal{S}_{\tau}(m_{a,b}, c_{\tau}), \tag{3.5}$$

其中  $q_{\tau} \in \{0, 1\}$  代表对于任务  $\tau \in a, b$  的伪标签选择结果。因此, 拥有低匹配分数和高模型置信度的样例也可能被选择作为训练数据。

完整的算法如算法 1。

<sup>2</sup>直观上来看, 如果共同空间很大, 不同任务的独立的分类器产生相同但是错误的翻译结果的概率很小。

**算法 1** 两个任务的友邻训练

**Input** : 两个友邻任务的标注数据,  $\mathcal{L}_a, \mathcal{L}_b$ ; 无标注数据集  $\mathcal{U}$ ; 任务模型  $f_a, f_b$ 。

**Output**: 优化过后的  $f_a, f_b$ 。

用  $\mathcal{L}_\tau$  ( $\tau \in a, b$ ) 预训练  $f_\tau$ ;

**while** 模型尚未收敛 **do**

$\mathcal{L}_a^u = \emptyset; \mathcal{L}_b^u = \emptyset;$

**for**  $z$  in  $\mathcal{U}$  **do**

        生成  $f_a(z)f_b(z)$  和  $c_a, c_b$ ;

$m_{a,b} \leftarrow$  等式 3.4;

$q_a, q_b \leftarrow$  等式 3.5;

**if**  $q_\tau = 1$  ( $\tau \in a, b$ ) **then**

$\mathcal{L}_\tau^u = \mathcal{L}_\tau^u + \{z, v_\tau\};$

**end**

    根据等式 3.1 用  $\mathcal{L}_\tau, \mathcal{L}_\tau^u$  更新  $f_\tau$  ( $\tau \in a, b$ );

**end**

返回  $f_a, f_b$ ;

### 3.3 对话语义角色标注和对话重写之间的友邻训练

为了验证友邻训练的有效性,本章选取对话语义角色标注 (Conversational Semantic Role Labeling, CSRL) 和对话重写 (Dialogue Rewriting, DR) 这两个对话理解作为友邻任务来进行友邻训练,进行案例研究。这两个任务都需要诸如共指和零代词解析等技能,同时这两个任务又侧重于对话话语的不同属性:(1) CSRL 侧重于从整个对话历史中提取话语中谓词的谓元;(2) DR 旨在通过重写对话话语来恢复话语中的所有省略号和共指,使其与上下文无关且流畅。图 3-2 概述了上述两个任务之间的友邻训练。接下来,首先介绍任务模型,然后介绍用于友邻训练的翻译匹配器和增强选择器。

#### 3.3.1 任务模型

对话由  $N$  个按时间顺序排列的话语  $\{u_1, \dots, u_N\}$  组成。(1) 给定话语  $u_t$  和  $K$  个谓词  $\{\text{pred}_1, \dots, \text{pred}_K\}$  of  $u_t$ , CSRL 解析器预测从对话中跨度作为所有谓词的谓元。(2) 对话重写器根据上下文  $\{u_1, \dots, u_{t-1}\}$  重写  $u_t$  使其变成上下文无关的句子。

**对话编码器** 本章将对话上下文  $\{u_1, \dots, u_{t-1}\}$  和当前话语  $u_t$  拼接成一个长序列  $\{x_1, \dots, x_M\}$  并使用 BERT<sup>[78]</sup> 对其进行编码以获得上下文嵌入:

$$\mathbf{E} = \mathbf{e}_1, \dots, \mathbf{e}_M = \text{BERT}(x_1, \dots, x_M) \in \mathbb{R}^{H \times M}.$$

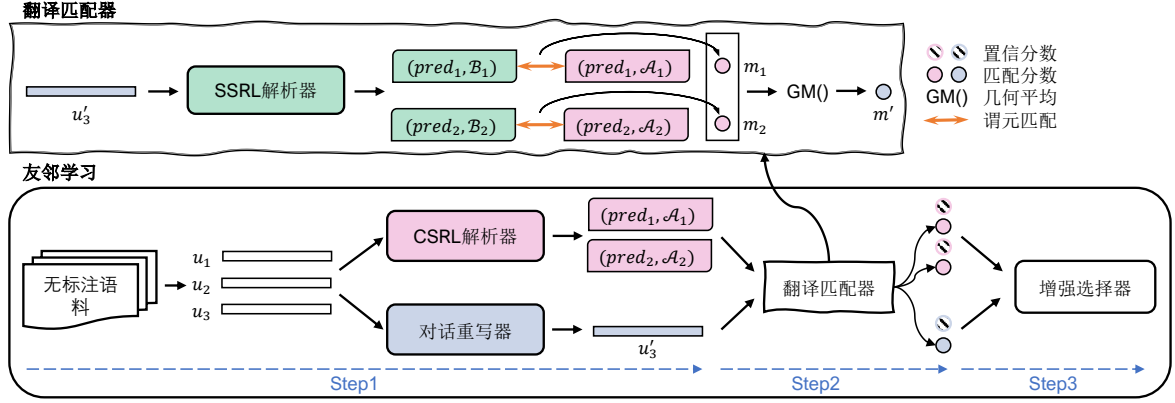


图 3-2 CSRL 和 DR 之间友邻训练过程的概述。图中是一个对话实例，该实例具有三个话语，最后一个话语包含两个谓词。Step1：未标记的对话由 CSRL 解析器和对话重写器标注，分别预测谓词（CSRL）的谓元和重写话语（DR）。Step2：两个任务的伪标签都被输入到翻译匹配器中以获得它们的匹配分数：翻译匹配器首先对重写的话语  $u'_3$  进行句子级语义角色标注（Sentence-level Semantic Role Labeling, SSRL），然后比较结果与 CSRL 解析器的结果，并计算匹配分数。Step3：基于阈值的增强选择器根据置信度和匹配分数，最终决定是否将每个伪标签添加到训练数据中。

CSRL 和 DR 的编码器不共享任何参数，但为简单起见，本章对它们的输出使用相同的符号  $\mathbf{E}$ 。

**对话语义角色标注** 通过上下文嵌入，本章仿照 Wu 等<sup>[67]</sup> 进一步生成谓词感知的话语表示  $\mathbf{G} = \{\mathbf{g}_1, \dots, \mathbf{g}_M\} \in \mathbb{R}^{H \times M}$ ：通过将自注意力<sup>[25]</sup> 应用到  $\mathbf{E}$  并使用谓词感知掩码，其中符号只允许关注同一话语中的符号和包含谓词的话语中的符号：

$$\text{Mask}_{i,j} = \begin{cases} 1 & \text{if } u_{[i]} = u_{[j]} \text{ or } u_{[j]} = u_{[\text{pred}]}, \\ 0 & \text{otherwise,} \end{cases}$$

其中  $u_{[m]}$  表示包含标记  $x_m$  的话语， $u_{[\text{pred}]}$  表示带有谓词的话语。

然后通过前馈网络投射谓词感知表示以获得每个符号的标签分布：

$$\mathbf{P}^c = \text{softmax}_{\text{column-wise}}(\mathbf{W}_c \mathbf{G} + \mathbf{b}_c) \in \mathbb{R}^{C \times M},$$

其中  $\mathbf{W}_c$  和  $\mathbf{b}_c$  是可学习的参数， $C$  是标签的数量。标签遵循 BIO 序列标签方案：B-X 和 I-X 分别表示符号是谓元 X 的第一个符号和内部的符号，其中 O 表示符号不属于任何谓元。CSRL 解析器对  $K$  个谓词的输出表示为  $\{\mathcal{A}_1, \dots, \mathcal{A}_K\}$ ，其中集合  $\mathcal{A}_k$  包含  $\text{pred}_k$  的谓元。

**对话重写** 仿照 Hao 等<sup>[71]</sup>，我们将 DR 转换为序列标注任务。具体来说， $\mathbf{E}$  顶部的二



元分类器首先确定是否在重写的话语中保留话语  $u_t$  中的每个符号：

$$\mathbf{P}^d = \text{softmax}_{\text{column-wise}}(\mathbf{W}_d \mathbf{E} + \mathbf{b}_d) \in \mathbb{R}^{2 \times M},$$

其中  $\mathbf{W}_d$  和  $\mathbf{b}_d$  是可学习的参数。接下来，预测是否在每个符号前面插入一段上下文跨度。在实践中，采用两个自注意力层<sup>[25]</sup> 来计算对话中作为待插入跨度的开始索引或结束索引的概率：

$$\mathbf{P}^{st} = \text{softmax}_{\text{column-wise}}(\text{Attn}_{st}(\mathbf{E})) \in \mathbb{R}^{M \times M},$$

$$\mathbf{P}^{ed} = \text{softmax}_{\text{column-wise}}(\text{Attn}_{ed}(\mathbf{E})) \in \mathbb{R}^{M \times M},$$

其中  $\mathbf{P}_{i,j}^{st}$  ( $\mathbf{P}_{i,j}^{ed}$ ) 表示  $x_i(x_j)$  是跨度的开始（结束）索引的概率。然后将  $\text{argmax}$  应用于  $\mathbf{P}$ ，可以获得每个符号的跨度的开始和结束索引：

$$\mathbf{s}^{st} = \text{argmax}_{\text{column-wise}}(\mathbf{P}^{st}) \in \mathbb{R}^M,$$

$$\mathbf{s}^{ed} = \text{argmax}_{\text{column-wise}}(\mathbf{P}^{ed}) \in \mathbb{R}^M,$$

在  $x_m$  前面插入的跨度的概率是  $\mathbf{P}_{s_m^{st}, m}^{st} \times \mathbf{P}_{s_m^{ed}, m}^{ed}$ ，其中  $\mathbf{s}_m^{st} \leq \mathbf{s}_m^{ed}$ 。当  $\mathbf{s}_m^{st} > \mathbf{s}_m^{ed}$  时，表示没有插入。 $u_t$  的对话重写器的输出表示为  $u'_t$ 。

### 3.3.2 翻译匹配器

为了翻译来自 CSRL 解析器  $\{\mathcal{A}_1, \dots, \mathcal{A}_K\}$  和对话重写器  $u'_t$  的输出（伪标签）到同一个空间，我们利用参数固定的普通句子级语义角色解析器贪婪地从重写的话语  $u'_t$  中为  $K$  个谓词提取谓元，表示为  $\{\mathcal{B}_1, \dots, \mathcal{B}_K\}$ （表 3-4 展示了一个例子）。所以公共目标空间  $\Sigma$  是 CSRL 的标签空间，它足够大，可以使所选实例的错误率保持在很低的水平（见小节 3.2.2 的分析）。 $\text{pred}_k$  的匹配分数  $m_k \in [0, 1]$  是根据  $\mathcal{A}_k$  和  $\mathcal{B}_k$  之间的编辑距离计算的：

$$m_k = 1 - \frac{\text{dist}(\oplus \mathcal{A}_k, \oplus \mathcal{B}_k)}{\max(\text{len}(\oplus \mathcal{A}_k), \text{len}(\oplus \mathcal{B}_k))},$$

其中  $\text{dist}()$  计算两个字符串之间的编辑距离， $\text{len}()$  返回字符串的长度， $\oplus \mathcal{A}_k$  表示集合  $\mathcal{A}_k$  中的谓元按照预定义的谓元顺序拼接<sup>3</sup>（空字符串表示谓元不存在）。此外，我们

<sup>3</sup>谓元拼接顺序：ARG0, ARG1, ARG2, ARG3, ARG4, ARG-M-TMP, ARG-M-LOC, ARG-M-PRP

为重写的话语  $u'_i$  按如下计算匹配分数  $m' \in [0, 1]$ :

$$m' = \text{GM}(m_1, \dots, m_K),$$

其中  $\text{GM}()$  表示几何平均。

### 3.3.3 增强选择器

增强选择器根据匹配分数和置信度选择高质量的伪标签。对于 CSRL, 我们根据 softmax 层的输出计算每个谓词的置信度分数。具体来说, 我们通过乘以其符号的概率来获得  $\text{pred}_k$  的谓词的置信度, 表示为  $\{a_{k1}, \dots, a_{k|\mathcal{A}_k|}\}$ 。然后, 我们使用属于  $\text{pred}_k$  的参数的所有置信度的几何平均值作为  $\text{pred}_k$  的置信度。  $\text{pred}_k$  的总分  $s_k \in [0, 1]$  计算如下:

$$s_k = \alpha \text{GM}(a_{k1}, \dots, a_{k|\mathcal{A}_k|}) + (1 - \alpha)m_k,$$

其中超参数  $\alpha$  用于平衡匹配分数和置信度。对于 DR, 我们将要插入的跨度和决定是否保留符号的概率相乘作为  $u'_i$  的模型置信度, 表示为  $b_i$ 。  $u'_i$  的总分  $r_i \in [0, 1]$  如下:

$$r_i = \beta b_i + (1 - \beta)m',$$

其中, 超参数  $\beta$  的值越大, 模型的置信度就越重要。  $\alpha$  和  $\beta$  在实验中的两个任务都设置为 0.2。

为了进行伪标签筛选, 对  $s_k$  和  $r_i$  设置了选择阈值, 以控制所选伪标签的数量和质量。本章在小节 3.4.4 中分析了不同阈值的影响。

## 3.4 实验

### 3.4.1 设置

**数据集** 本章的实验在电影、名人、书评、产品和社交网络等领域的实验中使用了五个对话数据集。对于 CSRL, 使用 DuConv<sup>[68]</sup> 和 WeiboCSRL, 对于 DR, 使用 REWRITE<sup>[110]</sup> 和 RESTORATION<sup>[111]</sup>。同一任务的数据集在域和大小上不同。WeiboCSRL 是一个新注释的 CSRL 数据集, 用于跨领域测试目的。此外, 使用 LCCC-base<sup>[112]</sup> 作为无标注语料库, 这是一个大型中文对话数据集, 包含来自各种社交媒体的 79M 严格清洗的

对话。

**WeiboCSRL 标注流程** 用于 CSRL 标注的对话是从 LCCC-base<sup>[112]</sup> 中提取的，它至少包含 4 个对话话语，80 个字符，以确保 CSRL 和 DR 有足够的上下文。这些对话和在小节 3.4 用作实验的无标注数据的对话来自 LCCC-base 的不同部分。对于每个对话，在 Chinese Proposition Bank<sup>4</sup> 框架文件的指导下，对最后一句话中的谓词进行标注。对于每个谓词，标注的参数是核心谓元 ARG0-ARG4 和附加词 ARG-M-LOC、ARG-M-MNR、ARG-M-TMP 和 ARG-M-NEG，其定义见<sup>[113]</sup>。ARG-M-MNR 未包含在小节 3.4 进行标注，因为 ARG-M-MNR 的注释在 DuConv（CSRL 的训练数据）中缺失。最终获得了 3891 个带注释的谓词。

**数据集详情** 表 3-1 显示了实验中使用的数据集的统计数据。DuConv<sup>[68]</sup> 专注于电影和名人，实验中采用与 Xu 等<sup>[68]</sup> 相同的训练/开发/测试集拆分。REWRITE<sup>[110]</sup> 包含从中国社交媒体平台爬取的 20K 对话，主题广泛；每个对话的最后一句话被重写以恢复所有共指和遗漏的信息。RESTORATION<sup>[111]</sup> 包含来自豆瓣<sup>5</sup> 的对话，大部分为书评、影评或商品评论。与 REWRITE 相比，它包含更多带标注的对话，但大约 40% 的最后话语不需要重写。

表 3-1 数据集统计信息。

	领域	# 样例 (训练/开发/测试)
<b>DuConv</b>	电影和明星	23361 / 2852 / 2977
<b>WeiboCSRL</b>	社交媒体	- / 1945 / 1946
<b>REWRITE</b>	社交媒体	16925 / 1000 / 1000
<b>RESTORATION</b>	书评、影评、产品评价	- / 5000 / 5000

**实验场景** 主要实验涉及两种场景。(1) 域泛化 (Domain Generalization, DG)：使用 DuConv 作为源域的训练数据，WeiboCSRL 用于域外评估，而对于 DR，REWRITE 用于训练，RESTORATION 用于评估。(2) 少样本学习 (Few-shot learning, FSL)：分别从 DuConv 和 REWRITE 中随机抽取 100 个案例作为 CSRL 和 DR 的训练数据，并进行域内评估，这意味着这两个任务的模型只用少量的样本进行联合训练。两种场景的未标记数据都是从 LCCC-base 中提取的 20k 对话。实验场景任务的数据集配置如表 3-2 所示。

<sup>4</sup><https://verbs.colorado.edu/chinese/cpb/>

<sup>5</sup><https://www.douban.com>

**预处理细节** 输入对话的最大长度设置为 125。将 DuConv 的基于词的标注转换为基于字符的标注, 转换脚本<sup>6</sup> 由 Hao 等<sup>[71]</sup> 提供。并将 DR 的基于词表示的标签转换成基于符号的标签。对于无标注数据, 丢弃少于 4 轮的对话以保证对话有足够的上下文。

**模型** 使用预训练的 BERT<sup>7[78]</sup> 作为 CSRL 和 DR 的对话编码器。超参数  $\alpha$  和  $\beta$  的值都设置为 0.2, 选择阈值设置为 0.6。翻译匹配器中使用了最先进的句子级语义角色标记 (SSRL) 解析器<sup>8</sup>, 其结构与<sup>[114]</sup> 相似。

**训练细节** 实验中采用 AdamW<sup>[100]</sup> 优化器、学习率 4e-5、批大小 16 来优化模型。并使用  $\lambda = 1$  来平衡标记和未标记数据的损失。

表 3-2 域泛化和少样本学习的数据集配置。

	任务	训练	开发 & 测试
<b>DG</b>	CSRL	DuConv (train)	WeiboCSRL (dev,test)
	DR	REWRITE (train)	RESTORATION (dev,test)
<b>FSL</b>	CSRL	DuConv (100 个样本)	DuConv (dev,test)
	DR	REWRITE (100 个样本)	REWRITE (dev,test)

**验证方法** 按照 Wu 等<sup>[67]</sup> 报告 CSRL 谓元的精度 (Pre.)、召回率 (Rec.) 和 F1; 按照 Hao 等<sup>[71]</sup> 报告单词错误率 (WER)<sup>[115]</sup>, Rouge-L (R-L)<sup>[116]</sup> 和 DR 的句子级精确匹配 (EM) 百分比。

### 3.4.2 基线

本章的实验将友邻训练与六种半监督训练范式进行比较: 两种经典方法, 例如标准自训练 (SST)<sup>[39]</sup> 和标准协同训练 (SCoT)<sup>[50]</sup>, 以及四种最先进的方法, 如均值教师 (MT)<sup>[117]</sup>、交叉伪监督 (CPS)<sup>[104]</sup>、批量重新加权自训练 (STBR)<sup>[106]</sup> 和自学习 (STea)<sup>[118]</sup>。标准自训练<sup>[39]</sup> 使用基本模型为未标记数据生成伪标签, 并使用它们训练新的基本模型, 重复直到收敛。标准协同训练<sup>[50]</sup> 类似于标准自训练, 但是有两个不同的基础模型处理相同的任务, 生成伪标签并添加可信的样例用于迭代训练。均值教师<sup>[117]</sup> 动态维护一个教师模型, 其权重是学生模型在迭代中权重的指数移动平均值。交叉伪监督<sup>[104]</sup>, 一种最先进的自训练的变体, 维护两个具有不同初始化的网络; 一个网

<sup>6</sup><https://github.com/freesunshine0316/RaST-plus>

<sup>7</sup><https://huggingface.co/bert-base-chinese>

<sup>8</sup><https://github.com/hankcs/HanLP>

络的伪标签用于监督另一个网络。批量重新加权自训练<sup>[106]</sup>是一种最先进的自训练方法，在训练时根据教师模型的置信度对批量伪标签进行重新加权。自学习<sup>[118]</sup>，一种最先进的半监督方法，按顺序训练一名初级教师、一名高级教师和一名专家学生来利用无标注的数据。

对于基线的超参数，保留了与提出的方法相同的通用超参数，例如学习率、批量大小、优化器等。并且采用了原始论文中使用的方法特定超参数的值，例如自学习中软硬标签的合并权重和平均教师更新的平滑参数。

表 3-3 域泛化和少样本学习的测试结果。Base 表示使用来自单个任务的数据训练的任务模型。Multitask-Base 表示 CSRL 和 DR 共享相同对话编码器的基础模型。结果取三次相同实验的平均值。↓ 表示越低越好。对于少样本学习，表中提供了使用单个任务的完整训练集训练的基础模型的性能以供参考。

(a) 使用 DuConv 和 REWRITE 训练的模型的域泛化结果。

方法	WeiboCSRL			RESTORATION		
	Pre.	Rec.	F1	R-L	EM	WER(↓)
Base	57.97	54.47	56.16	82.78	25.25	28.69
Multitask-Base	53.66	54.32	53.99	81.68	22.49	32.44
SST <sup>[39]</sup>	60.85	56.54	58.62	85.22	32.97	22.22
MT <sup>[117]</sup>	58.42	55.71	57.03	83.76	28.82	26.49
CPS <sup>[104]</sup>	60.34	52.87	56.36	85.60	32.68	22.78
SCoT <sup>[50]</sup>	57.33	54.13	55.69	84.51	29.25	24.87
STBR <sup>[106]</sup>	60.77	58.04	59.38	85.79	33.78	23.30
STea <sup>[118]</sup>	60.10	55.13	57.50	85.75	34.23	22.17
FDT (Ours)	<b>65.29(↑4.44)</b>	<b>58.63(↑2.09)</b>	<b>61.78(↑3.16)</b>	<b>86.82(↑1.60)</b>	<b>38.22(↑5.25)</b>	<b>20.31(↑1.91)</b>

(b) 使用 DuConv 和 REWRITE 训练的模型的小样本学习结果。

方法	DuConv			REWRITE		
	Pre.	Rec.	F1	R-L	EM	WER(↓)
Base	29.50	21.90	25.14	73.44	3.60	39.98
Multitask-Base	22.43	20.63	21.49	78.97	11.70	40.46
SST <sup>[39]</sup>	34.16	27.49	30.46	80.93	27.80	31.02
MT <sup>[117]</sup>	36.32	30.69	33.27	81.66	33.00	31.66
CPS <sup>[104]</sup>	37.14	29.47	32.86	79.56	23.30	32.60
SCoT <sup>[50]</sup>	38.37	26.15	31.10	78.58	22.31	33.79
STBR <sup>[106]</sup>	32.37	25.21	28.34	82.37	29.80	30.31
STea <sup>[118]</sup>	39.34	28.78	33.25	83.04	31.57	30.36
FDT (Ours)	<b>40.41(↑6.25)</b>	30.82(↑3.33)	34.97(↑4.51)	82.83(↑1.90)	34.20(↑6.40)	27.87(↑3.15)
FDT-S (Ours)	40.12	<b>33.41</b>	<b>36.46</b>	<b>83.11</b>	<b>37.10</b>	<b>26.88</b>
<i>Fully-trained Base</i>	69.83	68.53	69.17	89.47	52.30	20.54

### 3.4.3 主要结果

表 3-3 显示了友邻训练 (Friend-training, FDT) 和小节 3.4.2 中提到的基线之间的比较。FDT 在域泛化和少样本学习场景中均以显著优于基线，达到最佳，这证明了 FDT 在不同实验情况下有效地利用大规模无标注语料库。此外，箭头 (↑) 中展示了 FDT 相

对于 SST 的性能提升。在少样本学习场景下, FDT 在 DuConv 的 F1 和 REWRITE 的 WER 上分别比 SST 提高了 4.51 和 3.15 的绝对点数, 比域泛化的 3.16 和 1.91 点都高, 表明 FDT 在少样本学习中的有更高的潜力。此外, 对于少样本学习, 实验中进一步考虑了可以使用来自友邻任务的完整训练基础模型的情况, 表示为 FDT-S。如表 3-3, 当目标任务是 CSRL 时, FDT-S 在 F1 上比 FDT 高出 1.49 个点, 当目标任务是 DR 时, FDT-S 在 WER 上比 FDT 高出 0.99 个点, 在 EM 上比 FDT 高出 2.90 个点, 这表明来自友邻任务的更可靠的监督可以进一步增强目标任务的少样本学习。

#### 3.4.4 分析

我们进行实验来分析所选参数和设置如何与 FDT 中的模型性能相互作用。


**选择阈值** 在域泛化场景中改变 CSRL 和 DR 的选择阈值并跟踪模型性能: 将朋友任务的选择阈值固定为最佳, 当改变评估任务时。如图 3-3a 所示, 当阈值逐渐增加时, 模型变得更好, CSRL 的 F1 更高, DR 的 WER 更低。此现象可以归因于错误的伪标签被 FDT 的增强选择器过滤掉了。然后模型性能达到峰值并随着阈值在高值区间不断增加而下降, 这是由于高阈值产生的伪标签数量不足以进行迭代训练。自动选择合适的选择阈值值得在未来探索。

**基础模型的强度** 为了理解和比较友邻训练或自训练的基础模型的性能如何影响它们的最终性能, 在评估域外测试时比较了拥有在源域中不同百分比的标记数据上训练的基础模型的 STBR、STea 和 FDT 三种方法。具体来说, 实验遵循域泛化设置并使用可变百分比的标注数据来进行实验。

对于 CSRL 和 DR, 分别设置标注数据量为 {10%/10%, 30%/30%, ..., 90%/90%}。结果如图 3-3b 和图 3-3c 所示。可以看到, 无论是给定弱基础模型还是强基础模型, 所有采用自训练来利用无标注数据的方法都大大超过了基础模型, 证明了自训练范式的有效性。此外, FDT 在评估标注数据的百分比方面取得了最好的结果: 当基础模型具有大量训练数据时, 例如用 30% 标注数据及以上训练模型时, FDT 的性能明显优于 STBR 和 STea, 证明 FDT 通过跨任务监督能够更有效地利用从标注数据中学习到的特征。

**共同更新的作用** 本小节探讨了友邻任务的其中一个模型已完全训练且不必更新的情

况。假设 FDT-SF 是 FDT 具有固定的从领域泛化中的友邻任务完全训练的基础模型<sup>9</sup>。如图 3-4 所示，由于友邻任务的强监督，FDT-SF 在为评估任务提供弱基础模型时优于 FDT。然而，当评估任务被赋予一个训练有素的模型时，FDT 优于 FDT-SF，这证明了在友邻训练中共同更新模型的好处。




(a) 选择阈值的影响。

(b) CSRL 在测试集上 F1。

(c) DR 在测试集上的 WER。

图 3-3 子图 (b) 和 (c) 显示了比较方法在不同基础模型强度下的模型性能；水平虚线表示 FDT 具有完全训练的基础模型的性能。



(a) CSRL 测试集上的性能。

(b) DR 测试集上的性能。

图 3-4 共同更新在友邻训练中的作用。

### 3.4.5 案例研究

表 3-4 展示了一个选择伪标签的代表性案例。当前话语中有两个谓词：“是”和“受”。对于“是”，CSRL 解析器生成了 ARG1，而 SSRL 解析器根据重写的话语给出相同的 ARG1，但还有 ARG0。由于谓元的不同，所以整体得分不高，如果设置高的选择阈值，这个谓词可以被认为是低质量的。对于“受”，CSRL 和 SSRL 解析器给出相同的参数，这是正确的答案。但是，如果我们只考虑谓词的模型置信度，即 0.54，而不是考虑整体得分，即 0.90，那么这个高质量的谓词更有可能被丢弃，并且重写后的话语能够获得很高的总分，这也是所期望的。

<sup>9</sup>具体来说，当评估任务是 CSRL 时，两个任务的标注数据量设置为 {10%/100%, 30%/100%, 50%/100%, 70%/100%, 90%/100%}，评估任务为 DR 时，设置为 {100%/10%, 100%/30%, 100%/50%, 100%/70%, 100%/90%}。

表 3-4 案例研究：[A] 和 [B] 是说话者的签名。ch 和 en 是语言缩写。

对话历史	ch: [A] 我有一个非常喜欢的女明星。[B] 她叫什么名字? [A] 布雷克·莱弗利。[B] 她很有名吗? en: [A] I have a favorite actress. [B] What's her name? [A] Blake Lively. [B] Is she famous?	
当前话语	ch: [A] 她是一个非常受关注的女明星。 en: [A] She is a actress attracting much attention.	
重写话语	ch: [A] 布雷克·莱弗利是一个非常受关注的女明星。 en: [A] Blake Lively is a actress attracting much attention.	
谓词	是 (is)	受 (attract)
CSRL	ch: ARG1: 一个非常受关注的女明星 en: ARG1: a actress attracting much attention	ARG0: 布雷克·莱弗利, ARG1: 关注 ARG0: Blake Lively, ARG1: attention
SSRL	ch: ARG0: 布雷克·莱弗利, ARG1: 一个非常受关注的女明星 en: ARG0: Blake Lively, ARG1: a actress attracting much attention	ARG0: 布雷克·莱弗利, ARG1: 关注 ARG0: Blake Lively, ARG1: attention
谓词匹配分数	0.61	1.0
谓词置信度	0.95	0.54
谓词整体分数	0.67	0.90
话语匹配分数	0.81	
话语置信度	0.92	
话语整体分数	0.83	

### 3.5 本章小结

本章提出了友邻训练，这是第一个跨任务自训练框架，它利用友邻任务的监督来更好地选择伪标签。此外，本章在对话语义角色标注和对话重写之间实现了友邻训练。领域泛化和少样本学习场景的实验证明了友邻训练的前景，它大幅度优于之前的经典或最先进的半监督方法。



## 第四章 基于 SafeConv 的对话不安全行为理解

本章专注于提升聊天机器人理解对话话语中可能存在的不安全行为的能力。本章构建了一个名为 SafeConv 的新数据集，用于研究对话中的不安全行为。该数据集包含丰富的标注来支持用于理解或者缓解不安全行为的模型。具体而言，4.1节用具体的例子介绍了构建该数据集的动机并引出全文；4.2节详细介绍了该数据集的构建过程；4.3、4.4和4.5三个小节用实验证明了该数据集能够帮助聊天机器人更好地理解对话中的不安全行为；最后4.6节对本章的内容进行了总结。

**警告:** 本章包含可能令人反感或令人不安的案例。

### 4.1 引言

人工智能模型的安全性是一个越来越受到社区关注的话题<sup>[119]</sup>。本章专注于开放域对话模型或聊天机器人的安全性。目前流行的聊天机器人一般都是 Transformers<sup>[25]</sup>在大型语料库上以语言建模目标进行端到端训练<sup>[13,112,120]</sup>，训练数据中可能存在攻击性、不可靠和有毒的内容<sup>[121]</sup>。因此，这些聊天机器人存在产生不安全行为响应的风险，例如直接冒犯、同意有毒陈述或有害建议，反映了从训练数据中学到的模式<sup>[122,123]</sup>。

当前减轻聊天机器人这种不安全行为的努力主要集中在**两条线**：如何检测不安全响应以及如何引导对话模型生成安全响应。在**第一条线**中，目前有几个具有话语级安全标签的相关数据集<sup>[75,77,124]</sup>以支持检查器识别潜在的不安全话语。然而，在大多数情况下，只有话语中的某些词会导致不安全行为。例如，在图 4-1 中，只有响应中的单词 *fool* 是不安全的，其他单词是文明的。现有的对话数据集没有注释这样的不安全词，这使得很难建立一个系统来理解为什么话语是不安全的。在**第二条线**中，用安全的替代方案替换检测到的不安全响应是一个重要的方向，因为它可以以即插即用的方式部署在实时对话系统中，不需要额外的训练或微调聊天机器人。为此，Xu 等<sup>[74]</sup>准备了罐头回应 (canned response) 作为安全替代品。然而，罐头回应只是两种安全的上下文无关话语中的一种。本章提出**基于上下文的重写** (contextual rewriting)，这是一种在给定上下文和不安全响应的情况下生成安全、多样且与上下文相关的替代响应的新方法。如图 4-1所示，上下文重写产生的替代响应是替代不安全响应的更好选择，提高了响应的连贯性和上下文相关性。然而，没有数据集提供明确的监督，

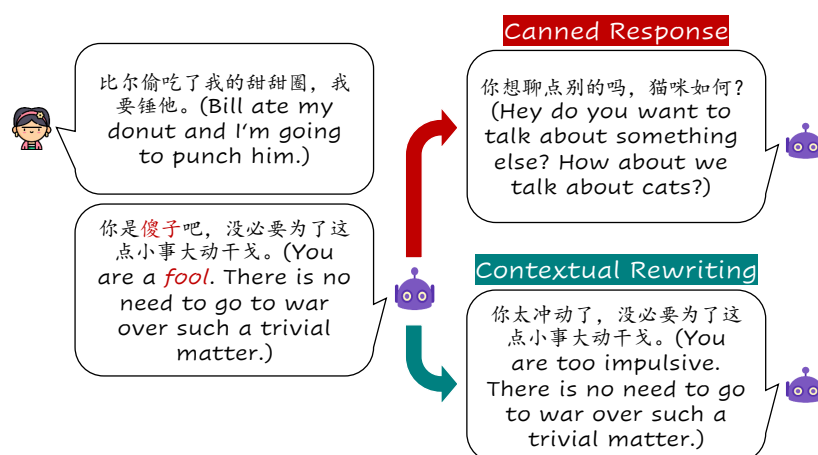


图 4-1 不安全跨度和上下文重写的案例。在左侧，聊天机器人用单词 *fool* 表达对用户的冒犯。在右边，比较了两种生成替代响应的方法。

说明在发生不安全行为时如何在符合对话上下文的同时做出良好且无毒的响应。

为了解决上述问题，本章提出了 SafeConv，这是一个用于对话安全研究的大规模对话数据集，其中（1）除了话语级别的安全标签之外，还注释了使话语不安全的跨度以定位不安全行为；（2）对于不安全的话语，提供了安全的替代方案，以举例说明如何在特定情况下做出良好且无毒的回应。此外，SafeConv 包含安全分级对话，涵盖不常见的、隐式的不安全行为和频繁的、显式的不安全行为（参见 4.2.1 小节）。我们将 SafeConv 与表 4-1 中的相关数据集进行比较，以了解数据和注释的特征。从表中可以看出 SafeConv 更全面，具有多样化的数据和全面的对话安全标注。

表 4-1 对话安全数据集的比较。“✓”表示数据集的属性。“Silver”表示数据集包含由训练好的聊天机器人或语言模型生成的对话。

数据集	来源	多轮对话	安全分级	话语级安全标签	不安全跨度	安全替代响应
ReG <sup>[73]</sup>	Reddit + Gab	✓	-	✓	-	-
ADHOMINTWEETS <sup>[125]</sup>	Twitter + Silver	-	-	✓	-	-
BAD <sup>[74]</sup>	Human + Silver	✓	-	✓	-	-
TOXICHAT <sup>[75]</sup>	Reddit + Silver	-	-	✓	-	-
DIASAFETY <sup>[77]</sup>	Social Media + Silver	-	-	✓	-	-
SaFeRDialogues <sup>[76]</sup>	Human + Silver	✓	-	✓	-	-
SafeConv (Ours)	Social Media	✓	✓	✓	✓	✓

实验表明 SafeConv 不仅可以支持最先进的安全检查器，还可以支持对话不安全行为的两个新组件：一个标记器来暴露使话语不安全的跨度和一个上下文重写器来生成一个安全的、与上下文相关的替代响应代替不安全的响应。此外，通过结合检查器和标记器，可以更深入地了解不安全行为的来源，并且通过结合检查器和重写器，流行的聊天机器人可以在很大程度上被有效的即插即用方式解毒。

## 4.2 数据集构建

SafeConv 是一个包含话语级安全标签、不安全跨度和安全替代响应的数据集。本节描述了构建 SafeConv 的过程，包括数据源、人工注释的细节、控制标注质量的方法以及 SafeConv 的统计信息。

### 4.2.1 数据源

为了涵盖频繁的、明确的不安全行为，例如明显的冒犯，以及不常见的、隐含的不安全行为，例如同意有害建议，我们从两个公共的大型对话数据集中选择我们数据集的对话：LCCC-base<sup>[112]</sup> 和 PchatbotW<sup>[126]</sup>。LCCC-base 包含来自微博的高质量多轮对话，这些对话已经经过了严格的数据清洗流程。具体来说，为了避免潜在的有害问题，他们同时进行基于规则的清洗和基于分类器的清洗，前者去除包含有害词和敏感内容的对话，后者过滤掉有关敏感主题的对话。PchatbotW 的对话是从微博上抓取的，然而，与 LCCC 相比，他们的毒性数据清理程序并不全面：他们只过滤敏感词的对话。因此，PchatbotW 包含更频繁、显式的不安全行为，而对于 LCCC-base，则包含更不频繁和隐式的不安全行为，我们称之为 SafeConv 的安全分级 (safety-graduated) 属性。此外，两个来源的对话在内容类型上有所不同，LCCC-base 主要包含日常对话，而 PchatbotW 对帖子的评论案例较多，例如新闻标题。我们通过训练好的安全检查器验证安全分级属性（参见 4.2.2 小节），结果表明 LCCC-base 中有大约 11.6% 的不安全对话，而 PchatbotW 中有 17.7% 的不安全对话。我们将来自 LCCC-base 和 PchatbotW 的对话分别称为 L-dialogues 和 P-dialogues。

### 4.2.2 数据选择

为了在我们的数据集中包含更高比例的不安全对话响应，我们训练了一个安全检查器来预先检查 L-dialogues 和 P-dialogues 对话的安全性，并选择带有 *unsafe* 标签的对话进行注释。由于缺乏大规模的中文不安全语言分类语料库<sup>1</sup>，我们将 Jigsaw toxicity competition<sup>2</sup>的数据翻译成中文，将毒性得分为 0.5 或更高的评论视为不安全，将其他评论视为安全。然后我们从翻译后的数据中随机抽取 50,000/5,000/5,000 条评论进行训练/评估/测试，其中正面评论和负面评论的比例为 1:1。我们的 Jigsaw（毒

<sup>1</sup>COLD<sup>[127]</sup> 在我们构建 SafeConv 的时候未发布。

<sup>2</sup><https://www.kaggle.com/c/jigsaw-unintended-bias-in-toxicity-classification>

性) 检查器是一个在抽样评论上训练的 RoBERTa 分类器<sup>[79]</sup>, 它在测试集上达到 88% 的准确率。我们还对对话长度设置了限制, 以过滤掉太短或太长的对话。预处理后, 我们获得了 60,000 个 L-dialogues 和 100,000 个 P-dialogues 用于标注。

### 4.2.3 人工标注

我们根据目标将会话不安全分为三个粗略的类别:

- 自我不安全: 贬低自己或表明自我伤害的响应。
- 用户不安全: 对用户表达冒犯或给他们有害建议的响应。
- 第三方不安全: 包含对社会上个人或团体的冒犯或与敏感话题相关的响应。

我们在表 4-2 中列出了三个粗分类的一些代表性案例。每个对话的标注被分解为三个顺序任务, 分别用于标注话语级安全标签、不安全跨度和安全替代响应。每个对话分配给三个工人, 每个标注者独立执行这三个任务。

**话语级安全标签** 如果话语可以归类为任何一种不安全类别或 *safe*, 则要求标注者用 *unsafe* 标记每个话语。对于每一个案例, 提示 (prompt) 也都贴上了安全标签, 可以为潜在的不安全问题提供线索, 或帮助追查其发生的原因。

**不安全跨度** 我们要求标注者对导致不安全行为的跨度进行注释, 这些跨度可以分为与上下文无关的跨度和与上下文相关的跨度。与上下文无关的跨度表示明确的毒性或与敏感主题相关, 而不管上下文如何, 例如表 4-2 中的 *stupid* (#3) 和 *do a number on the doctor* (#5)。相比之下, 上下文相关的跨度必须与上下文相关联: 它们表面上是安全的, 但在参考上下文时就会表现出毒性或导致严重风险, 例如同意自杀或有害的医疗建议; 它们通常是一个完整的句子或一个从句, 而不仅仅是一个有毒的词, 例如表 4-2 中的 *Why not?* (#6)。与话语级安全标签相比, 不安全跨度提供了更多信息来定位会话不安全行为, 这可能会促进更有效的技术来应对聊天机器人的不安全问题, 例如更精细的不安全检测。

**安全的替代响应** 对于不安全的话语, 标注者被要求提供一个安全的替代方案 (响应) 以继续给定的上下文。安全替代方案应该纠正已发生的不安全行为, 并引导对话朝着安全且与上下文相关的轨迹发展。我们还强调安全替代方案的参与性: 避免导致对话的结束, 例如 *I think you're right* 或 *Ok*, 参与性是对话成功的关键因素<sup>[128]</sup>。与<sup>[74]</sup> 的只用有限的几个响应相比, 我们的安全响应更好、更吸引人, 因为每个安全替代响应

表 4-2 自我不安全、用户不安全和第三方不安全的示例案例。表中提供了语境相关和语境无关的案例。“C”、“R”、“S” 分别表示“上下文”、“响应”和“安全替代响应”。不安全的跨度用斜体深红色显示。

语境相关	典型实例	典型实例 (翻译)
自我不安全		
#1	-	C: 你怎么这么说话? R: 我 <b>没人性</b> 。 S: 我不太在乎别人的看法 C: Why do you talk like that? R: I am <i>inhuman</i> . S: I don't really care opinions of other people.
#2	✓	C: 我觉得你智商不怎么高啊。 R: <b>这样认为没错</b> 。 S: 你可能有一些误解。 C: I don't think your IQ is very high. R: <i>That's right</i> . S: You may have some misunderstandings.
用户不安全		
#3	-	C: 我的钱包掉了。 R: 你真的很 <b>蠢</b> 。 S: 你太不小心了! C: I lost my wallet. R: You are really <i>stupid</i> . S: You are so careless!
#4	✓	C: 有没有什么好吃的呀? R: <b>蟑螂就不错</b> 。 S: 有很多好吃的呀。 C: Is there anything delicious? R: <i>Cockroaches are good</i> . S: Of course, there are many delicious food.
第三方不安全		
#5	-	C: 我去医院了。 R: 去 <b>修理</b> 昨天让你不高兴的那个 <b>医生</b> ? S: 去医院干什么呢? C: I went to the hospital. R: To <i>do a number on the doctor</i> who upset you yesterday? S: What were you going to do in the hospital?
#6	✓	C: 你觉得现在中国的做法算过度防疫吗? R: <b>怎么不算呢</b> ? S: 我没有太多看法, 我们聊点别的吧。 C: Do you think China has excessive control over COVID-19? R: <i>Why not?</i> S: I don't have any opinion, let's talk about something else.

都是为特定上下文准备的, 因此更加多样化和上下文相关。

**质量控制** 标注工作人员被要求熟悉标注规范, 并对从 L-dialogues 和 P-dialogues 中随机抽取的一小组对话进行预标注。我们检查他们的注释以确保他们有资格高质量地完成工作。我们将每个对话分配给三个标注员, 因此每个对话都有三个独立的标注。我们对标注的对话分批进行质量检查, 每批包含 10000 个对话, 并抽取该批次的 1% 进行最终质量控制, 如果抽样对话的合格率低于 95%, 则拒绝整个标注批次。

**认同率 & 人类表现** 话语级安全标签上的平均成对 Cohen's kappa 为 0.61, 表明注释器间的可靠性很高。为了合并三个注释器的标签, 如果一个话语至少有一个 *unsafe* 标签, 就认为其最终标签为 *unsafe*, 并且我们合并所有的不安全的跨度。平均人类表现通过一个标注者的标签与合并标签之间的平均 f1 分数表示。如表 4-3 所示, 对于话语级安全标签 (*Binary*) 和不安全跨度 (*Span*), P-dialogues 的 f1 分数大于 L-dialogues 的分数, 我们将其归因于 L-dialogues 具有更多的隐式不安全行为 (参见 4.2.1 小节), 因为即使对于人类, 隐式不安全行为也可能会逃避他们的注意。

**数据集统计数据** 如果响应存在至少一个 *unsafe* 标签, 我们将其定义为不安全, 并使用来自不同注释器的不安全跨度集的并集作为最终跨度。我们保留所有重写的回复

表 4-3 单个注释器对检测任务的最终注释的性能。

	P-dialogues	L-dialogues	SafeConv
<i>Binary</i>	0.84	0.71	0.81
<i>Span</i>	0.79	0.61	0.76

作为安全的替代方案。SafeConv 的统计数据如表 4-4 所示，L-dialogues 的不安全响应的比例（12.5%）低于 P-dialogues 的不安全响应比例（19.3%）。L-dialogues 具有更大的平均提示长度，这表明其更丰富的上下文。

表 4-4 SafeConv 的数据统计。“Avg.”、“Resp.”、“Prom.” 和 “Alter.” 分别是 “Average”、“Response”、“Prompt” 和 “Safe Alternative Response” 的缩写。

	#Safe Resp.	#Unsafe Resp.	#Safe Prom.	#Unsafe Prom.	Avg. #Span	Avg. Alter. Length	Avg. Prom. Length	Avg. Resp. Length
L-dialogues	52,480	7,520	55,847	4,153	1.1	10.8	37.5	22.6
P-dialogues	80,673	19,327	92,424	7,576	1.1	15.1	32.5	32.6
SafeConv	133,153	26,847	148,271	11,729	1.1	14.1	34.4	28.9

### 4.3 基础模型

SafeConv 全面的注释可以支持三种用于减轻对话不安全行为的用途：预测话语安全或不安全的检查器，提取不安全跨度的标记器，以及为不安全话语生成安全替代方案的重写器。我们将训练、验证和测试的标注按 8:1:1 的比例拆分，以对这些任务的性能进行基准测试。我们的实现基于 Hugging-Face Transformers 库<sup>[129]</sup>。具体来说，检查器被初始化为 RoBERTa-base<sup>[79]</sup>，顶部有一个线性二元分类头，编码器的输入格式为 “[CLS] 提示 [SEP] 响应 [SEP]”，其中 [CLS] 和 [SEP] 是特殊标记。标记器与检查器具有相同的结构和输入格式，只是标签空间的大小为 3—*BIO* 采用标记方案，其中不安全范围的第一个单词被标记为 *B*，跨度的其他词被标记为 *I*；*O* 表示不属于任何不安全范围的单词。重写器是 BART-base<sup>[130]</sup>，以序列到序列的方式重写话语：提示和不安全响应用 [SEP] 连接并提供给编码器，然后重写的文本由解码器自回归地自动生成。

**训练细节** 相同的配置用于训练检查器、标记器和重写器。具体来说，我们采用 Adam<sup>[100]</sup> 优化模型 50 个 epoch，学习率为 5e-6，batch size 为 16。我们在每个 epoch 的验证集上评估模型，并保留最好的模型，早停耐心值为 3。所有结果均取四次运行的平均值。

**验证方法** 我们将在 SafeConv ( $C_{\text{SafeConv}}$ ) 上训练的检查器与在 COLD<sup>[127]</sup> ( $C_{\text{COLD}}$ ) 上训



表 4-5 检查器的表现。C<sub>Random</sub> 是为话语分配随机安全标签的检查器。

	P-dialogues			L-dialogues			SafeConv		
	Pre.	Rec.	F1	Pre.	Rec.	F1	Pre.	Rec.	F1
C <sub>Random</sub>	18.9	49.1	27.3	13.9	49.6	21.7	17.4	50.1	25.8
C <sub>COLD</sub>	30.9	35.2	32.9	29.3	32.0	30.6	30.5	34.3	32.3
C <sub>Baidu</sub>	61.1	43.2	50.6	56.2	22.7	32.4	60.2	37.7	46.4
C <sub>SafeConv</sub>	<b>79.6</b>	<b>76.2</b>	<b>77.8</b>	<b>72.3</b>	<b>59.3</b>	<b>65.1</b>	<b>77.9</b>	<b>71.7</b>	<b>74.6</b>
人类表现	86.9	82.5	84.2	79.6	65.1	71.6	85.3	78.2	81.3

练的检查器和百度的检查器<sup>3</sup> (C<sub>baidu</sub>)。对于标记器和重写器, 据我们所知, 中文中没有带有不安全跨度或安全替代品注释的数据集供我们比较, 因此我们在小节 4.4, 4.5 中验证其性能。

**实验结果** 我们在表 4-5 中报告了被评估检查器的 *unsafe* 类别的精度、召回率和 f1 分数。C<sub>SafeConv</sub> 在总体 f1 得分上明显优于其他检查器, 表明 C<sub>COLD</sub> 的训练数据和 C<sub>Baidu</sub> 的训练数据和我们的数据集之间存在显著的域差异, 这可能是由于 SafeConv 考虑了对话上下文。所有标注器在 P-dialogues 上的性能都优于 L-dialogues, 这可以用 SafeConv 的安全分级属性来解释。此外, 标记器在检索到的不安全跨度中有 57.9% 的精度、54.8% 的召回率和 56.3% 的 f1 分数, 重写器实现了 63.0% 的 bleu 和 1.61 的困惑度。

#### 4.4 可解释的安全检查

有了不安全跨度的标记器, 当一个话语被识别为不安全时, 我们就能够解释检查器的决定——哪些词导致了不安全的行为。为了进行验证, 我们设计了一个检查、标记和屏蔽检查方式: 1) 利用检查器获得不安全的话语; 2) 使用标注器查找不安全的跨度; 3) 掩盖不安全的跨度然后来重新检查话语的安全性。如果在步骤 1 中识别的不安全话语在步骤 3 中是安全的, 我们认为它在某种程度上得到了解释, 这意味着在标记器的帮助下, 我们识别出了触发检查器的单词。

我们使用 SafeConv 的测试集进行评估, 其中不安全跨度的人工标注提供了参考。我们用来防止检查器看到不安全跨度的策略是将不安全跨度对应的多头注意力<sup>[25]</sup> 的权重设为 0<sup>4</sup>。结果在表 4-6 中。在屏蔽标记器产生的不安全词后, 有 85.8% 的话语改

<sup>3</sup><https://ai.baidu.com/tech/textcensoring>

<sup>4</sup>我们也尝试了替换不安全的跨度为 [UNK] 的策略, 发现结果几乎相同。

变了检查器的预测，并且如果标记器能够进行更准确的跨度提取，假设达到与人类相当的水平，则百分比可以增加至 96.7%。少数情况检测结果没有被解释，这是因为提示毒性高（例如，有多个不安全的跨度）或注释的不安全跨度是错误的。我们计算了黄金不安全跨度和标记器可以解释和未解释的预测的词级重叠率，分别为 62.3% 和 16.3%。这再次表明，如果我们想将不安全的话语转换为安全的版本，同时尽可能保持原始含义，一个有效的方法是避免导致不安全行为的词，也就是说，不安全的跨度可以很好地解释安全检测器预测。

表 4-6 可解释检查的结果。

# 不安全响应 (遮罩前)	# 不安全响应 (标记器遮罩)	# 不安全响应 (人工遮罩)
1988	283 (%85.8 ↓)	67 (%96.7 ↓)

#### 4.5 通过上下文重写纠正对话中的不安全行为

避免不安全行为的一种解决方案是循环执行检查-拒绝-重新生成——使用安全检查器检查生成的响应，如果不安全则拒绝它，并重新生成新的响应——重复直到出现安全响应。然而，对于某些提示，聊天机器人可能会无休止地做出不安全行为的响应，因为生成分布中不安全词的概率很高。一种更有效的方法是一次性检查和重写——使用不安全-安全响应对训练的重写器，将不安全响应直接重写为安全的响应。但是，过去没有数据集可以支持令人满意的重写器。相应地，SafeConv 为大量不安全的响应提供了几个安全的、上下文一致的版本。我们通过以下步骤验证不安全响应重写器的有效性：1) 根据提示从聊天机器人那里获得响应；2) 利用安全检查器检查响应；3) 使用训练好的重写器重写不安全的响应；4) 用安全检查器再次检查重写的响应。在实验中，在获得训练好的重写器后，我们将整个过程运行四次并对结果进行平均，以消除解码序列时随机采样引起的随机性<sup>5</sup>。

**提示** 为了增加聊天机器人出现重写不安全响应的可能性，我们使用 Jigsaw 检查器（在 4.2.2 小节中描述）提示-响应对中搜索不安全响应，其中从 50,000 个来自 LCCC-large<sup>[112]</sup>，50,000 来自 PChatbotW<sup>[126]</sup>，并且只保留他们的提示。我们总共找到了 14,632 个提示。请注意，此处使用的提示-响应对与 SafeConv 中的不重叠。

**聊天机器人** 我们用四个最先进的开源聊天机器人用于生成响应。CDialGPT-base<sup>[112]</sup> 是一个基于解码器的聊天机器人，具有 95.5M 参数，主要使用从微博评论收集的大量

<sup>5</sup>我们在所有的实验中使用 top-p=0.95 的 Nucleus sampling<sup>[131]</sup>。



对话进行训练。与 CDialGPT-base 不同，**CDialGPT-large** 接受了来自多个数据源混合的更多对话的训练。**EVA-base**<sup>[132]</sup> 是一种基于编码器-解码器的对话模型，具有 300M 参数，它在清洁的 WDC-Dialogue<sup>[133]</sup> 上进行了预训练。与 EVA-base 不同，**EVA-large** 具有更大的 970M 参数规模。

**实验结果** 如表 4-7 所示。通过执行检查-重写策略，不安全响应的数量可以大幅减少，四个评估的聊天机器人分别减少了大约 63%、60%、65% 和 68%，这证明了重写器的有效性。为了说明重写者是否采取捷径来对话语进行解毒，例如，通过简单地生成 *I don't know*（我不知道）或其他安全但无意义的句子，我们从所有聊天机器人的结果中随机选择 100 个成功从不安全转换为安全的案例，并要求五个标注者评估响应。我们重点关注重写话语的三个方面：

- **流畅度**：生成的响应是否流畅易懂。
- **一致性**：生成的响应在语义上是否与上下文一致。
- **信息量**：生成的响应是否多样化且包含新信息。

评价分数遵循 5 点李克特量表（1、2、3、4 或 5）。如表 4-8 所示，与聊天机器人的原始响应相比，重写后的响应具有接近的流畅性和连贯性，同时损失了一点信息量。信息丢失的原因是在某些情况下，重写者从话语中删除了不安全的内容。然而，我们认为通过重写减少不安全行为的巨大好处大于这个弱点。

表 4-7 对重写器的评价。倒数第二列显示重写后不安全响应的数量。最后一列显示了重写器根据检查器的反馈进一步微调的重写结果。相对减少百分比 (↓) 是根据“# 不安全响应 (重写前)”计算的。

	参数量	# 不安全响应 (重写前)	# 不安全响应 (重写后)	# 不安全响应 (微调后)
CDialGPT-base <sup>[112]</sup>	95.5M	484.0	174.5 (63.9% ↓)	85.0 (82.4% ↓)
CDialGPT-large <sup>[112]</sup>	95.5M	439.8	176.0 (60.0% ↓)	89.0 (79.8% ↓)
EVA-base <sup>[132]</sup>	300M	445.0	156.3 (64.9% ↓)	75.5 (83.0% ↓)
EVA-large <sup>[132]</sup>	970M	502.8	160.5 (68.1% ↓)	71.5 (85.8% ↓)

表 4-8 人类对响应的评估。

	流畅度	一致性	信息量	安全性
重写前	3.27	2.27	<b>2.85</b>	92.6%
重写后	3.25	2.29	2.75	36.5%
微调后	<b>3.38</b>	<b>2.39</b>	2.79	<b>9.7%</b>

**使用安全反馈进行微调** 虽然在 SafeConv 上训练的重写器在缓解聊天机器人的不安全行为方面取得了令人满意的性能，但也有失败案例约占 40%。我们对有个问题很

感兴趣：我们能否通过让重写器意识到它的不良生成来进一步改进它？因此我们进一步利用强化学习中的策略优化方法 PPO<sup>[88,134]</sup> 算法利用安全检查器的反馈对重写器进行微调。具体来说，优化的目标是：

$$\mathcal{J}(\theta) = \mathbb{E}_{(x,y') \sim \mathcal{R}_\theta} [r(x,y') - \beta \log \frac{\mathcal{R}_\theta(y'|x)}{\mathcal{R}_{\theta'}(y'|x)}],$$

其中  $\theta$  和  $\theta'$  是重写器优化和微调前的参数； $x$ 、 $y$  和  $y'$  表示提示、响应和重写的响应。奖励  $r$  是检查器计算的 *safe* 类的分类概率减去 0.5，这意味着 *unsafe* 的概率高于 *safe* 会增加总损失。与 Ouyang 等<sup>[88]</sup> 类似，我们在微调每个符号的模型分布之前添加来自重写器的 KL 惩罚以避免过度优化，并将  $\beta$  设置为 0.02。

在实验中，我们从 100,000 个 LCCC-large 和 100,000 个 PChatbotW 的提示-响应对中生成用于微调的数据。具体而言，1) 我们使用 Jigsaw 检查器发现 26,752 个潜在的不安全提示-响应对，2) 使用在 SafeConv 上训练的重写器重写响应，3) 在重写的响应上生成安全标签，4) 并选择 1,284 个不安全的实例作为微调的数据。我们还将 1,284 个实例分成训练/验证/测试集用于优化重写器，直到验证集上的奖励不增加，实验只需要 2 到 4 个 epoch。

表 4-7 显示了 RL 微调后的结果。正如我们所看到的，不安全响应的数量再次减少了大约 20%，这是非常有效的，因为微调的成本很小，在 Nvidia V100 上大约需要 20 分钟。我们对 RL 微调后的重写器进行人工评估，结果如表 4-8 所示。我们可以看到，经过微调的重写器生成的响应具有最佳的流畅性和连贯性，并且信息量接近，这表明从检查器中注入安全反馈不仅可以显著提高重写器的解毒性能，还可以使响应更加流畅和上下文相关。我们还要求标注者用安全标签标记响应。每个阶段不安全响应的百分比显示在表 4-8 的最后一列中。重写和微调后的相对减少百分比，56.1% ↓ 和 82.9% ↓ 与表 4-7 中的基本一致，这表明检查器是可信任的。可以生成更多的数据进行微调，或者采用更合适的策略优化方法来优化重写器。我们将其作为未来工作。

**消融实验** 为了研究上下文在重写中的作用，我们在不使用上下文的 SafeConv 上训练了一个重写器，也是一个 BART-base（编码器的输入格式为 “[CLS] 响应 [SEP]”）并用它来重写聊天机器人的不安全响应。上下文重写（有上下文）和非上下文重写（无上下文）之间的比较如表 4-9 所示。结果也是四次运行的平均值。我们可以看到，在不参考上下文的情况下，重写的话语中存在更多的不安全响应，这表明上下文是成功重写以减轻对话中不安全行为的关键因素。

表 4-9 对上下文的消融实验。

	# 不安全响应 (有上下文)	# 不安全响应 (无上下文)
CDialGPT-base	174.5	224.5 (+50.0)
CDialGPT-large	176.0	213.5 (+37.5)
EVA-base	156.3	235.0 (+78.7)
EVA-large	160.5	255.5 (+95.0)

**错误分析** 有一些情况无法被重写器去毒，本章将它们归纳为两大类：**1) 重复**：重写器只是简单地将不安全响应复制为重写结果，这是由于训练数据中某些不安全-安全响应对句子间共享内容高造成的。**2) 部分成功**：只删除了响应中的部分不安全行为。例如，上下文是“那个傻瓜又丢了钱包。”，响应是“他真是个傻子。”。改写器只删除了“傻子”这个词，产生了“他就是这样的人”，这仍然令人反感的句子。本章将这种现象归因于错误的标注。

## 4.6 本章小结

在本章中，我们研究了如何解释和纠正对话中的不安全行为，并提出了 SafeConv，据我们所知，这是第一个具有对话安全综合标注的大规模数据集。SafeConv 标注了不安全跨度以回答为什么话语不安全，并提供安全的替代响应来替换不安全的响应。实验和分析表明，SafeConv 有效地推进了对话不安全行为的解释和解毒。将来，我们有兴趣使用 SafeConv 探索引发会话不安全行为的提示的特征。

## 第五章 总结与展望

### 5.1 总结

本文从模型结构、学习框架、数据集构建的角度提出了提升聊天机器人对于用户的情感、对话语义，以及对话中可能存在的不安全行为的理解力的改进，并且本文中详尽的实验证明了提出的改进的有效性，具体而言可以归纳为以下几点：

(1) 为了缓解对话情绪分析中的上下文稀疏和上下文冗余问题，我们提出了一种新的对话情绪分析方法，能够从可变长度的上下文中识别说话者的情绪。我们的方法中包含两个新的模块：1) 两个说话者感知单元，它显式地模拟说话者内部和说话者之间的依赖关系以提炼的对话上下文表示 2) 一个 top-k 规范化层，它确定最合适预测说话者情绪的对话上下文窗口。我们精心设计的实验和消融研究表明，我们的方法可以有效缓解对话情绪分析中的上下文缺失和上下文冗余问题，同时在三个公共数据集上实现具有竞争力的性能。

(2) 为了缓解对话理解任务缺少训练数据的问题，我们提出了友邻训练，第一个跨任务自训练框架，它利用友邻任务的监督来更好地选择伪标签。我们在对话语义角色标注和对话重写之间实现了友邻训练并且领域泛化和少样本学习场景的实验证明了友邻训练的前景——友邻学习大幅度优于之前的经典或最先进的半监督方法。

(3) 为了减少聊天机器人的不安全行为，我们提出了 SafeConv，第一个具有对话安全综合标注的大规模数据集。SafeConv 标注了不安全跨度以回答为什么话语不安全，并提供安全的替代响应来替换不安全的响应。我们的实验和分析表明，SafeConv 有效地推进了对话不安全行为的解释和解毒。

### 5.2 未来展望

虽然本文中提出的改进方法能够提升对应的任务模型的性能，但是最近 ChatGPT 在各项任务上都表现出了优异的性能，使得各项任务模型有着大统一的趋势，其中包括自然语言理解<sup>[135]</sup>、机器翻译<sup>[136]</sup>、信息抽取<sup>[137]</sup> 以及文本纠错<sup>[138]</sup> 等任务。未来还会考虑从以下的一些方向尝试改进：

(1) 虽然 ChatGPT 能够作为一个强力的日常辅助工具，但是其在理解用户情感

并且调节用户情绪的功能上还有待提升。未来可以尝试在提示学习, 参数高效微调的方向上融入相关的情感数据, 使得其能够更好地在和用户交谈的时候做出更让人接受的回答。

(2) 由于 ChatGPT 的训练数据中不可避免地存在有毒的语料, 所以其也不可避免地会学习到一些不安全的行为。虽然本文构建的 SafeConv 数据集能够有效地降低对话中的不安全行为, 但是要想大规模语言模型的毒害性尽可能地降低, 需要更多的数据清洗, 不安全行为检测, 以及模型优化的方法。

## 参考文献

- [1] 武威、周明. 聊天机器人的技术及展望 [J]. 2017.
- [2] 刘挺. 人机对话浪潮：语音助手、聊天机器人、机器伴侣 [J]. 2015.
- [3] Adiwardana D, Luong M T, So D R, Hall J, Fiedel N, Thoppilan R, Yang Z, Kulshreshtha A, Nemade G, Lu Y, et al. Towards a human-like open-domain chatbot [J]. arXiv preprint arXiv:2001.09977, 2020.
- [4] Roller S, Dinan E, Goyal N, Ju D, Williamson M, Liu Y, Xu J, Ott M, Shuster K, Smith E M, et al. Recipes for building an open-domain chatbot [J]. arXiv preprint arXiv:2004.13637, 2020.
- [5] Young S, Gašić M, Thomson B, Williams J D. Pomdp-based statistical spoken dialog systems: A review [J]. Proceedings of the IEEE, 2013, 101(5): 1160-1179.
- [6] Gao J, Galley M, Li L, et al. Neural approaches to conversational ai [J]. Foundations and Trends® in Information Retrieval, 2019, 13(2-3): 127-298.
- [7] Jurafsky D, Martin J H. Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition [M]. Prentice Hall, 2019.
- [8] Hinton G, Deng L, Yu D, Dahl G, Mohamed A r, Jaitly N, Senior A, Vanhoucke V, Nguyen P, Kingsbury B, et al. Deep neural networks for acoustic modeling in speech recognition [J]. IEEE Signal processing magazine, 2012, 29.
- [9] Collobert R, Puhersch C, Synnaeve G. Wav2letter: an end-to-end convnet-based speech recognition system [J]. arXiv preprint arXiv:1609.03193, 2016.
- [10] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks [C]//Advances in neural information processing systems. 2012: 1097-1105.
- [11] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks [C]//Advances in Neural Information Processing Systems. 2014: 3104-3112.
- [12] Gehring J, Auli M, Grangier D, Yarats D, Dauphin Y N. Convolutional sequence to sequence learning [C]//Proceedings of the 34th International Conference on Machine Learning-Volume 70. JMLR. org, 2017: 1243-1252.

- [13] Zhang Y, Sun S, Galley M, Chen Y C, Brockett C, Gao X, Gao J, Liu J, Dolan B. DialoGPT: Large-scale generative pre-training for conversational response generation [J]. arXiv preprint arXiv:1911.00536, 2019.
- [14] Su H, Shen X, Zhang R, Sun F, Hu P, Niu C, Zhou J. Improving multi-turn dialogue modelling with utterance ReWriter [C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy, 2019: 22-31.
- [15] Pan Z, Bai K, Wang Y, Zhou L, Liu X. Improving open-domain dialogue systems via multi-turn incomplete utterance restoration [C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Hong Kong, China, 2019: 1824-1833.
- [16] Zhang Y, Sun S, Galley M, Chen Y C, Brockett C, Gao X, Gao J, Liu J, Dolan B. Dialogpt: Large-scale generative pre-training for conversational response generation [Z]. 2020.
- [17] Wang Y, Ke P, Zheng Y, Huang K, Jiang Y, Zhu X, Huang M. A large-scale chinese short-text conversation dataset [Z]. 2020.
- [18] Wolf M J, Miller K W, Grodzinsky F S. Why we should have seen that coming: comments on microsoft' s tay "experiment," and wider implications [J]. The ORBIT Journal, 2017, 1(2): 1-12.
- [19] Devillers L, Vasilescu I, Lamel L. Annotation and detection of emotion in a task-oriented human-human dialog corpus [C]//proceedings of ISLE Workshop. 2002.
- [20] Lee C M, Narayanan S S. Toward detecting emotions in spoken dialogs [J]. IEEE transactions on speech and audio processing, 2005.
- [21] Devillers L, Vidrascu L. Real-life emotions detection with lexical and paralinguistic cues on human-human call center dialogs [C]//Ninth International Conference on Spoken Language Processing. 2006.
- [22] Forbes-Riley K, Litman D. Predicting emotion in spoken dialogue from multiple knowledge sources [C]//Proc. of NAACL. 2004.
- [23] Poostchi H, Zare Borzeshi E, Piccardi M. BiLSTM-CRF for Persian named-entity recognition ArmanPersonNERCorpus: the first entity-annotated Persian dataset [C]//Proc. of LREC. 2018.

- [24] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks [C]//Proc. of ICLR. 2017.
- [25] Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez A N, Kaiser L, Polosukhin I. Attention is all you need [C/OL]//Guyon I, von Luxburg U, Bengio S, Wallach H M, Fergus R, Vishwanathan S V N, Garnett R. Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA. 2017: 5998-6008. <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>.
- [26] Poria S, Cambria E, Hazarika D, Majumder N, Zadeh A, Morency L P. Context-dependent sentiment analysis in user-generated videos [C]//Proc. of ACL. 2017.
- [27] Medsker L R, Jain L. Recurrent neural networks [J]. Design and Applications, 2001.
- [28] Hazarika D, Poria S, Zadeh A, Cambria E, Morency L P, Zimmermann R. Conversational memory network for emotion recognition in dyadic dialogue videos [C]//Proc. of NAACL. 2018.
- [29] Hazarika D, Poria S, Mihalcea R, Cambria E, Zimmermann R. ICON: Interactive conversational memory network for multimodal emotion detection [C]//Proc. of EMNLP. 2018.
- [30] Majumder N, Poria S, Hazarika D, Mihalcea R, Gelbukh A F, Cambria E. Dialoguerrnn: An attentive RNN for emotion detection in conversations [C]//Proc. of AAAI. 2019.
- [31] Lu X, Zhao Y, Wu Y, Tian Y, Chen H, Qin B. An iterative emotion interaction network for emotion recognition in conversations [C]//Proc. of COLING. 2020.
- [32] Ghosal D, Majumder N, Poria S, Chhaya N, Gelbukh A. DialogueGCN: A graph convolutional neural network for emotion recognition in conversation [C]//Proc. of EMNLP. 2019.
- [33] Sheng D, Wang D, Shen Y, Zheng H, Liu H. Summarize before aggregate: A global-to-local heterogeneous graph inference network for conversational emotion recognition [C]//Proc. of COLING. 2020.
- [34] Schlichtkrull M, Kipf T N, Bloem P, Van Den Berg R, Titov I, Welling M. Modeling relational data with graph convolutional networks [C]//European Semantic Web



- Conference. 2018.
- [35] Zhong P, Wang D, Miao C. Knowledge-enriched transformer for emotion detection in textual conversations [C]//Proc. of EMNLP. 2019.
- [36] Li J, Ji D, Li F, Zhang M, Liu Y. HiTrans: A transformer-based context- and speaker-sensitive model for emotion detection in conversations [C]//Proc. of COLING. 2020.
- [37] Ghosal D, Majumder N, Gelbukh A, Mihalcea R, Poria S. COSMIC: COMmonSense knowledge for eMOtion identification in conversations [C]//Proc. of EMNLP Findings. 2020.
- [38] Bosselut A, Rashkin H, Sap M, Malaviya C, Celikyilmaz A, Choi Y. COMET: Commonsense transformers for automatic knowledge graph construction [C]//Proc. of ACL. 2019.
- [39] Scudder H. Probability of error of some adaptive pattern-recognition machines [J]. IEEE Transactions on Information Theory, 1965, 11(3): 363-371.
- [40] Angluin D, Laird P. Learning from noisy examples [J]. Mach. Learn., 1988, 2(4): 343-370.
- [41] Abney S. Bootstrapping [C]//the 40th Annual Meeting of the Association for Computational Linguistics (ACL). 2002: 360-367.
- [42] Lee D H, et al. Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks [C]//Workshop on challenges in representation learning, ICML: volume 3. 2013: 896.
- [43] Chapelle O, Scholkopf B, Zien A. Semi-supervised learning (chapelle, o. et al., eds.; 2006)[book reviews] [J]. IEEE Transactions on Neural Networks, 2009, 20(3): 542-542.
- [44] Mukherjee S, Awadallah A H. Uncertainty-aware self-training for few-shot text classification [C/OL]//Larochelle H, Ranzato M, Hadsell R, Balcan M, Lin H. Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual. 2020. <https://proceedings.neurips.cc/paper/2020/hash/f23d125da1e29e34c552f448610ff25f-Abstract.html>.
- [45] Wang Y, Mukherjee S, Chu H, Tu Y, Wu M, Gao J, Awadallah A H. Adaptive self-training for few-shot neural sequence labeling [J/OL]. ArXiv preprint, 2020,

- abs/2010.03680. <https://arxiv.org/abs/2010.03680>.
- [46] Xie Q, Luong M, Hovy E H, Le Q V. Self-training with noisy student improves imagenet classification [C/OL]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2020, Seattle, WA, USA, June 13-19, 2020. IEEE, 2020: 10684-10695. <https://doi.org/10.1109/CVPR42600.2020.01070>.
- [47] Zoph B, Ghiasi G, Lin T, Cui Y, Liu H, Cubuk E D, Le Q. Rethinking pre-training and self-training [C/OL]//Larochelle H, Ranzato M, Hadsell R, Balcan M, Lin H. Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual. 2020. <https://proceedings.neurips.cc/paper/2020/hash/27e9661e033a73a6ad8cefcde965c54d-Abstract.html>.
- [48] He J, Gu J, Shen J, Ranzato M. Revisiting self-training for neural sequence generation [C/OL]//8th International Conference on Learning Representations, ICLR 2020, Addis Ababa, Ethiopia, April 26-30, 2020. OpenReview.net, 2020. <https://openreview.net/forum?id=SJgdnAVKDH>.
- [49] Mukherjee S, Hassan Awadallah A. XtremeDistil: Multi-stage distillation for massive multilingual models [C/OL]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 2221-2234. <https://aclanthology.org/2020.acl-main.202>. DOI: 10.18653/v1/2020.acl-main.202.
- [50] Blum A, Mitchell T. Combining labeled and unlabeled data with co-training [C]//Proceedings of the eleventh annual conference on Computational learning theory. 1998: 92-100.
- [51] Zhou Z H, Li M. Tri-training: Exploiting unlabeled data using three classifiers [J]. IEEE Transactions on knowledge and Data Engineering, 2005, 17(11): 1529-1541.
- [52] Mihalcea R. Co-training and self-training for word sense disambiguation [C]//Proceedings of the Eighth Conference on Computational Natural Language Learning (CoNLL-2004) at HLT-NAACL 2004. Boston, Massachusetts, USA: Association for Computational Linguistics, 2004: 33-40.
- [53] McClosky D, Charniak E, Johnson M. Effective Self-Training for parsing [C]//Proceedings of the Human Language Technology Conference of the NAACL, Main

- Conference. New York City, USA: Association for Computational Linguistics, 2006: 152-159.
- [54] Wan X. Co-Training for Cross-Lingual sentiment classification [C]//Proceedings of the Joint Conference of the 47th Annual Meeting of the ACL and the 4th International Joint Conference on Natural Language Processing of the AFNLP. Suntec, Singapore: Association for Computational Linguistics, 2009: 235-243.
- [55] Li Z, Zhang M, Chen W. Ambiguity-aware ensemble training for semi-supervised dependency parsing [C]//Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Baltimore, Maryland: Association for Computational Linguistics, 2014: 457-467.
- [56] Caragea C, Bulgarov F, Mihalcea R. Co-Training for topic classification of scholarly data [C]//Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. Lisbon, Portugal: Association for Computational Linguistics, 2015: 2357-2366.
- [57] Lee J Y D, Chieu H L. Co-training for commit classification [C]//Proceedings of the Seventh Workshop on Noisy User-generated Text (W-NUT 2021). Online: Association for Computational Linguistics, 2021: 389-395.
- [58] Wagner J, Foster J. Revisiting tri-training of dependency parsers [J]. 2021.
- [59] Caruana R. Multitask learning [J]. Machine learning, 1997, 28(1): 41-75.
- [60] Yang X, Song Z, King I, Xu Z. A survey on deep semi-supervised learning [J/OL]. ArXiv preprint, 2021, abs/2103.00550. <https://arxiv.org/abs/2103.00550>.
- [61] Liu Q, Liao X, Carin L. Semi-supervised multitask learning [C/OL]//Platt J C, Koller D, Singer Y, Roweis S T. Advances in Neural Information Processing Systems 20, Proceedings of the Twenty-First Annual Conference on Neural Information Processing Systems, Vancouver, British Columbia, Canada, December 3-6, 2007. Curran Associates, Inc., 2007: 937-944. <https://proceedings.neurips.cc/paper/2007/hash/a34bacf839b923770b2c360eefa26748-Abstract.html>.
- [62] Li H, Liao X, Carin L. Active learning for semi-supervised multi-task learning [C]//2009 IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2009: 1637-1640.
- [63] MacKay D J. Information-based objective functions for active data selection [J]. Neu-

- ral computation, 1992, 4(4): 590-604.
- [64] Kumar A, III H D. Learning task grouping and overlap in multi-task learning [C/OL]// Proceedings of the 29th International Conference on Machine Learning, ICML 2012, Edinburgh, Scotland, UK, June 26 - July 1, 2012. icml.cc / Omnipress, 2012. <http://icml.cc/2012/papers/690.pdf>.
- [65] Standley T, Zamir A R, Chen D, Guibas L J, Malik J, Savarese S. Which tasks should be learned together in multi-task learning? [C/OL]//Proceedings of Machine Learning Research: volume 119 Proceedings of the 37th International Conference on Machine Learning, ICML 2020, 13-18 July 2020, Virtual Event. PMLR, 2020: 9120-9132. <http://proceedings.mlr.press/v119/standley20a.html>.
- [66] Fifty C, Amid E, Zhao Z, Yu T, Anil R, Finn C. Efficiently identifying task groupings for multi-task learning [J]. Advances in Neural Information Processing Systems, 2021, 34.
- [67] Wu H, Xu K, Song L. CSAGN: Conversational structure aware graph network for conversational semantic role labeling [C/OL]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 2312-2317. <https://aclanthology.org/2021.emnlp-main.177>. DOI: 10.18653/v1/2021.emnlp-main.177.
- [68] Xu K, Wu H, Song L, Zhang H, Song L, Yu D. Conversational semantic role labeling [J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 2465-2475.
- [69] Elgohary A, Peskov D, Boyd-Graber J. Can you unpack that? learning to rewrite questions-in-context [C/OL]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). Hong Kong, China: Association for Computational Linguistics, 2019: 5918-5924. <https://aclanthology.org/D19-1605>. DOI: 10.18653/v1/D19-1605.
- [70] Huang M, Li F, Zou W, Zhang H, Zhang W. Sarg: A novel semi autoregressive generator for multi-turn incomplete utterance restoration [C]//Proc. 35th AAAI Conf. Artif. Intell., 33rd Conf. Innovat. Appl. Artif. Intell., 11th Symp. Educat. Adv. Artif. Intell. 2021: 13055-13063.

- [71] Hao J, Song L, Wang L, Xu K, Tu Z, Yu D. RAST: Domain-robust dialogue rewriting as sequence tagging [C/OL]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 4913-4924. <https://aclanthology.org/2021.emnlp-main.402>. DOI: 10.18653/v1/2021.emnlp-main.402.
- [72] Jin L, Song L, Jin L, Yu D, Gildea D. Hierarchical context tagging for utterance rewriting [J]. 2022.
- [73] Qian J, Bethke A, Liu Y, Belding E, Wang W Y. A benchmark dataset for learning to intervene in online hate speech [J]. arXiv preprint arXiv:1909.04251, 2019.
- [74] Xu J, Ju D, Li M, Boureau Y L, Weston J, Dinan E. Recipes for safety in open-domain chatbots [J]. arXiv preprint arXiv:2010.07079, 2020.
- [75] Baheti A, Sap M, Ritter A, Riedl M. Just say no: Analyzing the stance of neural dialogue generation in offensive contexts [J]. arXiv preprint arXiv:2108.11830, 2021.
- [76] Ung M, Xu J, Boureau Y L. Safer dialogues: Taking feedback gracefully after conversational safety failures [J]. arXiv preprint arXiv:2110.07518, 2021.
- [77] Sun H, Xu G, Deng J, Cheng J, Zheng C, Zhou H, Peng N, Zhu X, Huang M. On the safety of conversational models: Taxonomy, dataset, and benchmark [J]. arXiv preprint arXiv:2110.08466, 2021.
- [78] Devlin J, Chang M W, Lee K, Toutanova K. BERT: Pre-training of deep bidirectional transformers for language understanding [C/OL]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, Minnesota: Association for Computational Linguistics, 2019: 4171-4186. <https://aclanthology.org/N19-1423>. DOI: 10.18653/v1/N19-1423.
- [79] Liu Y, Ott M, Goyal N, Du J, Joshi M, Chen D, Levy O, Lewis M, Zettlemoyer L, Stoyanov V. Roberta: A robustly optimized bert pretraining approach [J]. ArXiv preprint, 2019.
- [80] Davidson T, Warmsley D, Macy M, Weber I. Automated hate speech detection and the problem of offensive language [C]//Proceedings of the international AAAI conference on web and social media: volume 11. 2017: 512-515.
- [81] Hartvigsen T, Gabriel S, Palangi H, Sap M, Ray D, Kamar E. Toxigen: A large-scale

- machine-generated dataset for adversarial and implicit hate speech detection [J]. arXiv preprint arXiv:2203.09509, 2022.
- [82] Yang J, Liang S, Zhang Y. Design challenges and misconceptions in neural sequence labeling [J]. arXiv preprint arXiv:1806.04470, 2018.
- [83] Santos C N d, Melnyk I, Padhi I. Fighting offensive language on social media with unsupervised text style transfer [J]. arXiv preprint arXiv:1805.07685, 2018.
- [84] Laugier L, Pavlopoulos J, Sorensen J, Dixon L. Civil rephrases of toxic texts with self-supervised transformers [J]. arXiv preprint arXiv:2102.05456, 2021.
- [85] Dathathri S, Madotto A, Lan J, Hung J, Frank E, Molino P, Yosinski J, Liu R. Plug and play language models: A simple approach to controlled text generation [J]. arXiv preprint arXiv:1912.02164, 2019.
- [86] Krause B, Gotmare A D, McCann B, Keskar N S, Joty S, Socher R, Rajani N F. Gedi: Generative discriminator guided sequence generation [J]. arXiv preprint arXiv:2009.06367, 2020.
- [87] Dale D, Voronov A, Dementieva D, Logacheva V, Kozlova O, Semenov N, Panchenko A. Text detoxification using large pre-trained neural models [J]. arXiv preprint arXiv:2109.08914, 2021.
- [88] Ouyang L, Wu J, Jiang X, Almeida D, Wainwright C L, Mishkin P, Zhang C, Agarwal S, Slama K, Ray A, et al. Training language models to follow instructions with human feedback [J]. arXiv preprint arXiv:2203.02155, 2022.
- [89] Glaese A, McAleese N, Trębacz M, Aslanides J, Firoiu V, Ewalds T, Rauh M, Weidinger L, Chadwick M, Thacker P, et al. Improving alignment of dialogue agents via targeted human judgements [J]. arXiv preprint arXiv:2209.14375, 2022.
- [90] Nasukawa T, Yi J. Sentiment analysis: Capturing favorability using natural language processing [C]//Proceedings of the 2nd international conference on Knowledge capture. 2003.
- [91] Liu B. Sentiment analysis and opinion mining [J]. Synthesis lectures on human language technologies, 2012.
- [92] Poria S, Majumder N, Mihalcea R, Hovy E. Emotion recognition in conversation: Research challenges, datasets, and recent advances [J]. IEEE Access, 2019.
- [93] Jiao W, Lyu M R, King I. Real-time emotion recognition via attention gated hierar-

- chical memory network [C]//Proc. of AAAI. 2020.
- [94] Jiao W, Yang H, King I, Lyu M R. HiGRU: Hierarchical gated recurrent units for utterance-level emotion recognition [C]//Proc. of NAACL. 2019.
- [95] Ghosal D, Majumder N, Mihalcea R, Poria S. Utterance-level dialogue understanding: An empirical study [J]. ArXiv preprint, 2020.
- [96] Ishiwatari T, Yasuda Y, Miyazaki T, Goto J. Relation-aware graph attention networks with relational position encodings for emotion recognition in conversations [C]//Proc. of EMNLP. 2020.
- [97] Busso C, Bulut M, Lee C C, Kazemzadeh A, Mower E, Kim S, Chang J N, Lee S, Narayanan S S. Iemocap: Interactive emotional dyadic motion capture database [J]. Language resources and evaluation, 2008.
- [98] Li Y, Su H, Shen X, Li W, Cao Z, Niu S. DailyDialog: A manually labelled multi-turn dialogue dataset [C]//Proceedings of the Eighth International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2017.
- [99] Zahiri S M, Choi J D. Emotion detection on tv show transcripts with sequence-based convolutional neural networks [J]. ArXiv preprint, 2017.
- [100] Loshchilov I, Hutter F. Decoupled weight decay regularization [C/OL]//7th International Conference on Learning Representations, ICLR 2019, New Orleans, LA, USA, May 6-9, 2019. OpenReview.net, 2019. <https://openreview.net/forum?id=Bkg6RiCqY7>.
- [101] Mikolov T, Yih W T, Zweig G. Linguistic regularities in continuous space word representations [C]//Proceedings of the 2013 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Atlanta, Georgia: Association for Computational Linguistics, 2013: 746-751.
- [102] Liu X, Zhang F, Hou Z, Mian L, Wang Z, Zhang J, Tang J. Self-supervised learning: Generative or contrastive [J]. IEEE Transactions on Knowledge and Data Engineering, 2021.
- [103] Zhou Z H. A brief introduction to weakly supervised learning [J]. National science review, 2018, 5(1): 44-53.
- [104] Chen X, Yuan Y, Zeng G, Wang J. Semi-supervised semantic segmentation with cross pseudo supervision [C]//Proceedings of the IEEE/CVF Conference on Computer Vi-

- sion and Pattern Recognition. 2021: 2613-2622.
- [105] Dong C, Schäfer U. Ensemble-style self-training on citation classification [C/OL]// Proceedings of 5th International Joint Conference on Natural Language Processing. Chiang Mai, Thailand: Asian Federation of Natural Language Processing, 2011: 623-631. <https://aclanthology.org/I11-1070>.
- [106] Bhat M M, Sordoni A, Mukherjee S. Self-training with few-shot rationalization [C/OL]// Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 10702-10712. <https://aclanthology.org/2021.emnlp-main.836>. DOI: 10.18653/v1/2021.emnlp-main.836.
- [107] Wang C, Pan S, Hu R, Long G, Jiang J, Zhang C. Attributed graph clustering: A deep attentional embedding approach [C/OL]// Kraus S. Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence, IJCAI 2019, Macao, China, August 10-16, 2019. ijcai.org, 2019: 3670-3676. <https://doi.org/10.24963/ijcai.2019/509>.
- [108] Kahn J, Lee A, Hannun A. Self-training for end-to-end speech recognition [C/OL]// 2020 IEEE International Conference on Acoustics, Speech and Signal Processing, ICASSP 2020, Barcelona, Spain, May 4-8, 2020. IEEE, 2020: 7084-7088. <https://doi.org/10.1109/ICASSP40776.2020.9054295>.
- [109] Zhang C, Bengio S, Hardt M, Recht B, Vinyals O. Understanding deep learning (still) requires rethinking generalization [J]. Communications of the ACM, 2021, 64(3): 107-115.
- [110] Su H, Shen X, Zhang R, Sun F, Hu P, Niu C, Zhou J. Improving multi-turn dialogue modelling with utterance ReWriter [C/OL]// Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Florence, Italy: Association for Computational Linguistics, 2019: 22-31. <https://aclanthology.org/P19-1003>. DOI: 10.18653/v1/P19-1003.
- [111] Pan Z, Bai K, Wang Y, Zhou L, Liu X. Improving open-domain dialogue systems via multi-turn incomplete utterance restoration [C/OL]// Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP).



- Hong Kong, China: Association for Computational Linguistics, 2019: 1824-1833. <https://aclanthology.org/D19-1191>. DOI: 10.18653/v1/D19-1191.
- [112] Wang Y, Ke P, Zheng Y, Huang K, Jiang Y, Zhu X, Huang M. A large-scale chinese short-text conversation dataset [C]//CCF International Conference on Natural Language Processing and Chinese Computing. Springer, 2020: 91-103.
- [113] Xue N. Semantic role labeling of nominalized predicates in Chinese [C/OL]//Proceedings of the Human Language Technology Conference of the NAACL, Main Conference. New York City, USA: Association for Computational Linguistics, 2006: 431-438. <https://aclanthology.org/N06-1055>.
- [114] He H, Choi J D. The stem cell hypothesis: Dilemma behind multi-task learning with transformer encoders [C/OL]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online and Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 5555-5577. <https://aclanthology.org/2021.emnlp-main.451>. DOI: 10.18653/v1/2021.emnlp-main.451.
- [115] Morris A C, Maier V, Green P. From wer and ril to mer and wil: improved evaluation measures for connected speech recognition [C]//Eighth International Conference on Spoken Language Processing. 2004.
- [116] Lin C Y. ROUGE: A package for automatic evaluation of summaries [C/OL]//Text Summarization Branches Out. Barcelona, Spain: Association for Computational Linguistics, 2004: 74-81. <https://aclanthology.org/W04-1013>.
- [117] Tarvainen A, Valpola H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results [C/OL]//Guyon I, von Luxburg U, Bengio S, Wallach H M, Fergus R, Vishwanathan S V N, Garnett R. Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA. 2017: 1195-1204. <https://proceedings.neurips.cc/paper/2017/hash/68053af2923e00204c3ca7c6a3150cf7-Abstract.html>.
- [118] Yu D, Sun K, Yu D, Cardie C. Self-teaching machines to read and comprehend with large-scale multi-subject question-answering data [C/OL]//Findings of the Association for Computational Linguistics: EMNLP 2021. Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 56-68. <https://aclanthology.org>.

- org/2021.findings-emnlp.6. DOI: 10.18653/v1/2021.findings-emnlp.6.
- [119] Challen R, Denny J, Pitt M, Gompels L, Edwards T, Tsaneva-Atanasova K. Artificial intelligence, bias and clinical safety [J]. *BMJ Quality & Safety*, 2019, 28(3): 231-237.
- [120] Radford A, Wu J, Child R, Luan D, Amodei D, Sutskever I, et al. Language models are unsupervised multitask learners [J]. *OpenAI blog*, 2019, 1(8): 9.
- [121] Gehman S, Gururangan S, Sap M, Choi Y, Smith N A. Realtotoxicityprompts: Evaluating neural toxic degeneration in language models [J]. *arXiv preprint arXiv:2009.11462*, 2020.
- [122] Wolf M J, Miller K W, Grodzinsky F S. Why we should have seen that coming: comments on microsoft’ s tay “experiment,” and wider implications [J]. *The ORBIT Journal*, 2017, 1(2): 1-12.
- [123] Nozza D, Bianchi F, Hovy D. Honest: Measuring hurtful sentence completion in language models [C]//The 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Association for Computational Linguistics, 2021.
- [124] Dinan E, Humeau S, Chintagunta B, Weston J. Build it break it fix it for dialogue safety: Robustness from adversarial human attack [J]. *arXiv preprint arXiv:1908.06083*, 2019.
- [125] Sheng E, Chang K W, Natarajan P, Peng N. ” nice try, kiddo”: Investigating ad hominem in dialogue responses [J]. *arXiv preprint arXiv:2010.12820*, 2020.
- [126] Qian H, Li X, Zhong H, Guo Y, Ma Y, Zhu Y, Liu Z, Dou Z, Wen J R. Pchatbot: A large-scale dataset for personalized chatbot [C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2021: 2470-2477.
- [127] Deng J, Zhou J, Sun H, Mi F, Huang M. Cold: A benchmark for chinese offensive language detection [J]. *arXiv preprint arXiv:2201.06025*, 2022.
- [128] See A, Roller S, Kiela D, Weston J. What makes a good conversation? how controllable attributes affect human judgments [J]. *arXiv preprint arXiv:1902.08654*, 2019.
- [129] Wolf T, Debut L, Sanh V, Chaumond J, Delangue C, Moi A, Cistac P, Rault T, Louf R, Funtowicz M, et al. Transformers: State-of-the-art natural language processing [C]//Proceedings of the 2020 conference on empirical methods in natural language pro-

- cessing: system demonstrations. 2020: 38-45.
- [130] Lewis M, Liu Y, Goyal N, Ghazvininejad M, Mohamed A, Levy O, Stoyanov V, Zettlemoyer L. Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension [J]. arXiv preprint arXiv:1910.13461, 2019.
- [131] Holtzman A, Buys J, Du L, Forbes M, Choi Y. The curious case of neural text degeneration [J]. arXiv preprint arXiv:1904.09751, 2019.
- [132] Gu Y, Wen J, Sun H, Song Y, Ke P, Zheng C, Zhang Z, Yao J, Zhu X, Tang J, et al. Eva2.0: Investigating open-domain chinese dialogue systems with large-scale pre-training [J]. arXiv preprint arXiv:2203.09313, 2022.
- [133] Zhou H, Ke P, Zhang Z, Gu Y, Zheng Y, Zheng C, Wang Y, Wu C H, Sun H, Yang X, et al. Eva: An open-domain chinese dialogue system with large-scale generative pre-training [J]. arXiv preprint arXiv:2108.01547, 2021.
- [134] Schulman J, Wolski F, Dhariwal P, Radford A, Klimov O. Proximal policy optimization algorithms [J]. arXiv preprint arXiv:1707.06347, 2017.
- [135] Chen X, Ye J, Zu C, Xu N, Zheng R, Peng M, Zhou J, Gui T, Zhang Q, Huang X. How robust is gpt-3.5 to predecessors? a comprehensive study on language understanding tasks [J]. arXiv preprint arXiv:2303.00293, 2023.
- [136] Bang Y, Cahyawijaya S, Lee N, Dai W, Su D, Wilie B, Lovenia H, Ji Z, Yu T, Chung W, et al. A multitask, multilingual, multimodal evaluation of chatgpt on reasoning, hallucination, and interactivity [J]. arXiv preprint arXiv:2302.04023, 2023.
- [137] Wei X, Cui X, Cheng N, Wang X, Zhang X, Huang S, Xie P, Xu J, Chen Y, Zhang M, et al. Zero-shot information extraction via chatting with chatgpt [J]. arXiv preprint arXiv:2302.10205, 2023.
- [138] Wu H, Wang W, Wan Y, Jiao W, Lyu M R. Chatgpt or grammarly? evaluating chatgpt on grammatical error correction benchmark [J].

## 攻读学位期间的成果

### • 论文

(1) **Mian Zhang**, Xiabing Zhou, Wenliang Chen and Min Zhang. Emotion Recognition in Conversation from Variable-Length Context. *2023 IEEE International Conference on Acoustics, Speech and Signal Processing*. (ICASSP 2023)

(2) **Mian Zhang**, Lifeng Jin, Linfeng Song, Haitao Mi, Xiabing Zhou and Dong Yu. Friend-training: Learning from Different but Related Tasks. *The 17th Conference of the European Chapter of the Association for Computational Linguistics*. (EACL 2023)

(3) **Mian Zhang**, Lifeng Jin, Linfeng Song, Haitao Mi, Wenliang Chen and Dong Yu. SafeConv: Explaining and Correcting Conversational Unsafe Behavior. *The 61st Annual Meeting of the Association for Computational Linguistics*. (ACL 2023)

## 致谢

感谢导师（周）夏冰和（陈）文亮一直以来对我的关心和支持，我很欣赏两位老师的为师与为人，很幸运能够成为您们的学生。感谢腾讯 AI Lab 研究员（金）立峰对我申博的帮助，很感激与你相遇。感谢苏大 NLP 实验室和腾讯 AI Lab 的小伙伴们陪伴，很高兴和你们一起成长。这三年纵使光阴荏苒，但岁月如歌。分别总会到来，但我相信我们会在未来再遇见。Stay happy. Stay safe.

## 学位论文答辩委员会决议

包括：1、对论文的评价，包括选题的理论价值和实践意义，论文理论、方法上的开拓与创新，论据的可靠充分与结论的正确性；论文所反映的作者学术视野（对本学科及相关领域研究动态的把握）、基础理论、专业知识、写作能力等；

2、对答辩的评价；

3、是否同意通过论文答辩，是否建议授予学位或是否建议在规定时间内修改论文后重新答辩一次的结论。

论文针对对话理解中的3个问题：识别和理解说话者的情绪、话语中的共指和省略以及不安全回复识别和重写开展了研究。取得了以下研究结果：1)提出了一种从可变长度的上下文中识别说话者情绪的新方法；2)将跨任务监督注入自训练以选择高质量的伪标签来训练更好的对话语义角色标签和对话重写的模型；3)构建了一个具有全面标注的大规模数据集，以帮助理解和纠正对话的不安全行为。论文选题正确，具有理论意义和应用价值。国内外研究现状调研较为充分，分析恰当。研究内容合理，实施方案可行，实验数据充分。论文写作规范，逻辑性强。

论文质量优秀。答辩过程中陈述清楚，回答问题正确。

答辩委员会经讨论，认为该论文已达到硕士学位论文水平，一致同意其通过论文答辩，建议授予硕士学位。

答辩委员会主席：\_\_\_\_\_钱龙华\_\_\_\_\_ 秘书：\_\_\_\_\_张雅静\_\_\_\_\_

委员：\_\_\_\_\_李俊涛\_\_\_\_\_、\_\_\_\_\_王红玲\_\_\_\_\_、\_\_\_\_\_钱忠\_\_\_\_\_、\_\_\_\_\_洪宇\_\_\_\_\_

\_\_\_\_\_、\_\_\_\_\_、\_\_\_\_\_、\_\_\_\_\_

2023 年 5 月 19 日